

**МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И
ИНФОРМАТИКИ
Кафедра биомедицинской информатики**

**ИССЛЕДОВАНИЕ МЕТОДОВ ПРЕДСТАВЛЕНИЯ И ГЕНЕРАЦИИ
МОЛЕКУЛЯРНЫХ СТРОК С ИСПОЛЬЗОВАНИЕМ РЕКУРРЕНТНЫХ
НЕЙРОННЫХ СЕТЕЙ**

Курсовой проект

Кондратёнка Владимира Васильевича
обучающегося 3 курса
специальности ”информатика”

Научный руководитель:
старший преподаватель,
А.Д. Карпенко

Минск, 2025

СОДЕРЖАНИЕ

Перечень сокращений и обозначений	3
Введение	5
Глава 1 Теоретические основы и базовые методы генерации молекул	8
1.1 Представление молекулярных структур для задач машинного обучения	8
1.2 Моделирование молекулярных структур как последовательностей с использованием рекуррентных нейронных сетей	11
1.3 Генеративные модели на основе вариационных автоэнкодеров . . .	13
Глава 2 Анализ современных архитектур и подходов к целевой генерации .	15
2.1 Гетероэнкодеры и вариационные автоэнкодеры: оптимизация в латентном пространстве	15
2.2 Обучение с подкреплением (Reinforcement Learning) для прямой оптимизации свойств	23
2.3 Сравнительный анализ подходов к целевой генерации	26
Глава 3 Оценка, ограничения и перспективы развития генеративных моделей	28
3.1 Стандартизация оценки: бенчмарки и метрики	28
3.2 Перспективы развития: за пределами RNN и SMILES	31
Заключение	33
Библиографический список	36

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

AAE	Adversarial Autoencoder (сопоставительный автоэнкодер)
AUC	Area Under the Curve (площадь под кривой)
CL	Curriculum Learning (обучение по учебному плану)
CPU	Central Processing Unit (центральный процессор)
DAP	Difference between Augmented and Posterior
DFT	Density Functional Theory (теория функционала плотности)
ELBO	Evidence Lower Bound (нижняя граница правдоподобия)
ELC	Explicit Latent Conditioning (явное обусловливание латентного пространства)
FCD	Fréchet ChemNet Distance (расстояние Фреше в пространстве ChemNet)
GCN	Graph Convolutional Networks (графовые сверточные сети)
GNN	Graph Neural Networks (графовые нейронные сети)
GPU	Graphics Processing Unit (графический процессор)
GRU	Gated Recurrent Unit (управляемый рекуррентный блок)
InChI	International Chemical Identifier (международный химический идентификатор)
JT-VAE	Junction Tree Variational Autoencoder
LLM	Large Language Model (большая языковая модель)
LogP	Коэффициент распределения октанол-вода
LSTM	Long Short-Term Memory (долгая краткосрочная память)
MD-VAE	Multi-Decoder Variational Autoencoder
MOSES	Molecular Sets
NLP	Natural Language Processing (обработка естественного языка)
OOD	Out-of-Distribution (вне распределения)
pLogP	Penalized LogP (штрафованный LogP)
QSAR	Quantitative Structure-Activity Relationship (количественное соотношение структура-активность)

RL	Reinforcement Learning (обучение с подкреплением)
RNN	Recurrent Neural Network (рекуррентная нейронная сеть)
SA score	Synthetic Accessibility score (оценка синтетической доступности)
SMILES	Simplified Molecular-Input Line-Entry System (упрощенная система представления молекул)
TPSA	Topological Polar Surface Area (топологическая полярная площадь поверхности)
VAE	Variational Autoencoder (вариационный автоэнкодер)
АИ	Искусственный интеллект
ВИЧ	Вирус иммунодефицита человека
ΔG	Энергия связывания Гиббса
EC_{50}	Концентрация полумаксимального эффекта
R^2	Коэффициент детерминации

ВВЕДЕНИЕ

Разработка новых лекарственных препаратов является одной из наиболее сложных и ресурсоемких задач современной медицинской химии. Традиционные подходы к дизайну молекул часто связаны с длительным процессом поиска структуры эффективного ингибитора и долгим дорогостоящим тестированием. В последние годы методы глубокого обучения произвели революцию во многих областях, и медицинская химия не стала исключением. Применение глубоких генеративных моделей, способных изучать закономерности в больших массивах химических данных и создавать новые, химически осмысленные соединения, открывает беспрецедентные возможности для ускорения процесса открытия лекарств [1; 2]. Представление молекулярных структур в виде текстовых нотаций, таких как SMILES, позволило рассматривать задачу их генерации как задачу моделирования последовательностей [3]. Это, в свою очередь, открыло возможность для применения мощных архитектур из области обработки естественного языка, в частности, рекуррентных нейронных сетей (RNN) [3]. Исследование и совершенствование этих методов является ключевым фактором для создания эффективных инструментов автоматизированного дизайна молекул с заданными биологическими и физико-химическими свойствами.

Несмотря на значительный прогресс, применение глубоких генеративных моделей в дизайне лекарств сталкивается с рядом фундаментальных проблем. Во-первых, это проблема создания такого числового представления молекулярной структуры, которое бы сохраняло ключевую топологическую и химическую информацию и было бы пригодно для использования в моделях глубокого обучения. Текстовые нотации, такие как SMILES, InChI и их производные (например, DeepSMILES), удобны для обработки моделями последовательностей, но вносят синтаксические и семантические ограничения. Это приводит к генерации невалидных или химически неадекватных структур, что стимулировало разработку более робастных форматов, таких как SELFIES [4]. Во-вторых, существует проблема управляемости генеративного процесса. Базовые модели способны генерировать разнообразные молекулы, но не позволяют целенаправленно создавать соединения с заранее определенным набором свойств. Решение этой проблемы требует разработки более сложных архитектур, таких как вариационные автоэнкодеры (VAE) и модели на основе

обучения с подкреплением (RL), каждая из которых имеет свои сильные и слабые стороны.

- **Объект исследования** – процесс *de novo* дизайна молекулярных структур с помощью методов глубокого обучения.
- **Предмет исследования** – методы представления (в частности, SMILES) и генерации (на основе RNN, VAE и RL) молекулярных строк для целенаправленного создания химических соединений с желаемыми свойствами.

Целью данной курсовой работы является комплексное исследование и сравнительный анализ современных методов представления и генерации молекулярных строк на основе нейронных сетей для задач целенаправленного дизайна молекул.

Для достижения поставленной цели были определены следующие задачи:

1. Изучить теоретические основы представления молекулярных структур для задач машинного обучения, уделив особое внимание нотации SMILES, ее преимуществам и недостаткам.
2. Рассмотреть базовые архитектуры генеративных моделей, такие как рекуррентные нейронные сети и вариационные автоэнкодеры, и их раннее применение для генерации химических структур.
3. Провести детальный анализ современных подходов к целевой генерации, включая оптимизацию в латентном пространстве (гетероэнкодеры, условные VAE) и методы обучения с подкреплением (RL).
4. Исследовать проблемы стандартизации оценки генеративных моделей, фундаментальные ограничения строковых представлений и определить перспективные направления развития в данной области.

В ходе работы применялись следующие методы: системный анализ научной и технической литературы по темам медицинской химии и глубокого обучения; сравнительный анализ архитектур нейронных сетей и подходов к целевой генерации; методы статического анализа кода для изучения практических реализаций моделей; обобщение и систематизация данных для формирования целостной картины текущего состояния и перспектив развития области.

Работа носит обзорно-аналитический характер. Ее практическая значимость заключается в систематизации знаний о современных архитектурах и подходах к генеративному дизайну молекул. Представленный анализ может служить теоретической основой для выбора и разработки эффективных

вычислительных инструментов для *de novo* создания новых лекарственных препаратов и химических соединений с заданными свойствами.

ГЛАВА 1

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И БАЗОВЫЕ МЕТОДЫ ГЕНЕРАЦИИ МОЛЕКУЛ

Разработка новых лекарственных препаратов с помощью методов глубокого обучения требует решения двух фундаментальных задач: представления сложной молекулярной структуры в формате, понятном для нейронной сети, и создания генеративных моделей, способных оперировать этим представлением для создания новых, химически осмысленных соединений. Данная глава посвящена рассмотрению теоретических основ, лежащих в основе этих процессов. Будет проанализирована текстовая нотация SMILES, ставшая стандартом де-факто для представления молекул в виде последовательностей, а также рассмотрены базовые архитектуры, такие как рекуррентные нейронные сети (RNN) и вариационные автоэнкодеры (VAE), которые первыми продемонстрировали свою эффективность в задачах *de novo* дизайна молекул.

1.1 Представление молекулярных структур для задач машинного обучения

Ключевым шагом, позволившим применить методы обработки естественного языка (Natural Language Processing, NLP) к задачам медицинской химии, стала разработка текстовых нотаций для представления молекулярных структур. Наиболее широкое распространение получила система **SMILES (Simplified Molecular-Input Line-Entry System)** – формат, представляющий молекулу в виде строки символов ASCII. Данный подход был разработан с целью создания машиночитаемого, но при этом компактного и интуитивно понятного для человека представления [4].

Принцип кодирования структуры в SMILES основан на наборе простых правил:

- **Атомы** представляются стандартными символами из периодической таблицы (например, C для углерода, N для азота). Атомы в ароматических системах обозначаются строчными буквами (например, бензол кодируется как c1ccccc1).

- **Связи** одинарные подразумеваются по умолчанию. Двойные и тройные связи обозначаются символами = и # соответственно.
- **Ветвления** боковых цепей от основного скелета молекулы заключаются в круглые скобки (). Например, изобутан представляется строкой CC(C)C.
- **Циклы** кодируются путем разрыва одной из связей в цикле. Атомы, соединенные этой связью, помечаются одинаковыми цифровыми индексами. Например, циклогексан можно представить как C1CCCCC1, где цифра 1 указывает на замыкание цикла между первым и последним атомами углерода.

Представление SMILES обладает рядом преимуществ, главным из которых является его совместимость с моделями глубокого обучения. Рассматривая молекулу как «предложение» на «химическом языке», исследователи смогли напрямую применить к задачам дизайна лекарств мощные архитектуры, такие как рекуррентные нейронные сети (RNN) и трансформеры. Кроме того, SMILES-строки компактны и более читаемы для человека по сравнению с другими форматами, такими как таблицы связности (connection tables), что упрощает работу с базами данных [4].

Тем не менее, у данного подхода есть и существенные недостатки. Основной проблемой является **неканоничность**: одна и та же молекула может быть представлена множеством синтаксически корректных SMILES-строк (например, CCO и OCC для этанола). Это усложняет сравнение структур и требует вычислительно затратных процедур канонизации. Другой важный недостаток заключается в том, что генеративные модели, обученные на SMILES, часто производят синтаксически некорректные строки (например, с непарными скобками). Это создает риск того, что модель в первую очередь изучает синтаксис нотации, а не фундаментальные химические закономерности. Наконец, в базовой форме SMILES не кодирует 3D-информацию о конформации молекулы, что является критически важным для многих задач.

Для решения этих проблем были разработаны альтернативные подходы. В частности, стандарт **InChI (International Chemical Identifier)** был создан с целью получения абсолютно уникальной, канонической строки для любой молекулярной структуры, что полностью решает проблему неоднозначности SMILES. В отличие от SMILES, где канонизация является отдельной, хотя и стандартной процедурой, InChI по своей природе является строго детерминированным идентификатором, предназначенным в первую очередь

для безошибочной индексации и поиска в базах данных. Однако именно эта строгость и сложная иерархическая структура делают InChI менее удобным для генеративных моделей. Строка InChI состоит из нескольких последовательных, четко разграниченных слоев, каждый из которых кодирует отдельный аспект структуры (например, химическую формулу, связи между атомами, стереохимию, изотопный состав). Такая многоуровневая и жестко регламентированная грамматика значительно сложнее для изучения нейронными сетями по сравнению с относительно простым и гомогенным синтаксисом SMILES. Модели, такие как RNN или трансформеры, обучаясь на InChI, рискуют потратить большую часть своих ресурсов на изучение правил самой нотации, а не на усвоение фундаментальных химических закономерностей, что делает SMILES и его производные более прагматичным выбором для задач *de novo* дизайна.

Более фундаментальной альтернативой строковым представлениям являются **молекулярные графы**, где атомы представляются узлами (вершинами), а химические связи – ребрами. Такое представление является наиболее естественным для молекулярных структур, так как оно напрямую кодирует топологию связей, а не ее сериализованную версию. Ключевое преимущество этого подхода заключается в том, что генеративные модели, оперирующие графами, по своей природе не могут создать синтаксически невалидную структуру (например, с «непарной связью» или незамкнутым циклом). Например, архитектура вариационного автоэнкодера на деревьях сочленений (Junction Tree VAE) [5]. Однако работа с графовыми данными требует применения специализированных архитектур, таких как графовые нейронные сети (Graph Neural Networks, GNN), способные обучаться на нерегулярных структурах путем агрегации информации от соседних узлов.

Тем не менее, строковые нотации продолжают активно развиваться, так как они позволяют напрямую использовать мощные архитектуры из области обработки естественного языка. Были предприняты попытки решить проблемы SMILES, не отказываясь от текстового представления. Одним из таких подходов является нотация **SELFIES (Self-referencing embedded strings)**, которая гарантирует 100% синтаксическую валидность генерируемых строк за счет использования самодостаточных токенов, каждый из которых представляет собой корректную химическую операцию. Более глубокий подход предложен в нотации **fragSMILES**, которая переходит от представления на уровне «атомных букв» к уровню «химических слов»

– осмысленных молекулярных фрагментов. Вместо последовательной генерации атомов модель учится комбинировать готовые строительные блоки, соединяя их специальными токенами, указывающими на точки присоединения. Такой подход решает не только синтаксические, но и семантические проблемы SMILES. В частности, fragSMILES предлагает надежный механизм кодирования хиральности, встраивая информацию о R/S-конфигурации непосредственно в токен соединения, что делает ее инвариантной к порядку обхода атомов в графе и значительно снижает долю ошибок при генерации стереоизомеров [6].

Наконец, следует упомянуть классический подход медицинской химии – **молекулярные отпечатки (fingerprints)**. В отличие от перечисленных выше представлений, которые являются обратимыми (по ним можно восстановить структуру молекулы), отпечатки представляют собой дескрипторы фиксированной длины. Они кодируют молекулу в виде бинарного или целочисленного вектора, где каждый элемент отражает наличие или отсутствие определенного структурного фрагмента или топологической особенности. Одним из наиболее распространенных примеров являются **ECFP4 (Extended-Connectivity Fingerprints)** – циркулярные отпечатки, которые итеративно кодируют информацию об окружении каждого атома в радиусе до четырех связей. Несмотря на то что отпечатки не подходят для генеративных задач, они остаются «золотым стандартом» для задач предсказательного моделирования (QSAR) и часто используются в качестве сильного базового метода (baseline) для сравнения с признаками, извлеченными моделями глубокого обучения [7].

1.2 Моделирование молекулярных структур как последовательностей с использованием рекуррентных нейронных сетей

Исторически первыми и наиболее влиятельными архитектурами для генерации молекул стали рекуррентные нейронные сети (RNN), в частности их более сложная разновидность – сети с долгой краткосрочной памятью (Long Short-Term Memory, LSTM). Принцип их работы в контексте химии основан на концепции авторегрессионной языковой модели. SMILES-строка разбивается на последовательность токенов (отдельных символов), и модель

обучается на каждом шаге предсказывать следующий токен на основе всех предыдущих. В процессе генерации модель, начиная со стартового токена, посимвольно «пишет» новую SMILES-строку, постоянно опираясь на уже сгенерированную часть последовательности [4]. Ранние работы в этой области продемонстрировали высокую эффективность, масштабируемость и, что самое главное, практическую применимость данного подхода.

Одним из первых масштабных исследований, доказавших состоятельность RNN-подхода, стала работа Ertl et al. (2017) [3]. Обучив относительно простую двухслойную LSTM-сеть на 509,000 биоактивных молекул из базы данных ChEMBL, авторы продемонстрировали возможность генерации **одного миллиона химически корректных молекул менее чем за два часа**. Несмотря на то, что только 32% от всех сгенерированных строк оказались валидными, новизна результата была чрезвычайно высока: лишь 0.3% сгенерированных структур совпадали с молекулами из обучающего набора. Ключевым достижением работы стала многоуровневая валидация, которая показала, что распределения физико-химических свойств (молекулярный вес, LogP, TPSA) и оценки синтетической доступности (SA score) у сгенерированных молекул практически идентичны реальным соединениям из ChEMBL. Наиболее убедительным доказательством стало применение QSAR-моделей, которое показало, что новые молекулы имеют сопоставимый с известными лекарствами потенциал биологической активности.

В то время как работа Ertl et al. продемонстрировала масштабируемость, исследование Bjerrum и Threlfall (2017) [8] было сфокусировано на детальном анализе качества и новизны генерируемых структур. Обучая модель на различных подмножествах базы ZINC («фрагменто-подобные» и «лекарственно-подобные» молекулы), они показали, что RNN способна точно воспроизводить распределения свойств из обучающей выборки. Это доказывает, что модель улавливает скрытые «химические правила», заложенные в данных. Анализ новизны показал, что до **83%** сгенерированных молекул отсутствовали в исходном обучающем наборе, при этом их оценка синтетической доступности (SA score) имела такое же распределение, как и у реальных соединений. Таким образом, было доказано, что модель генерирует не просто валидные, но и химически осмысленные, новые и потенциально синтезируемые структуры.

Кульминацией ранних исследований стала работа, продемонстрировавшая переход от теоретических выкладок к реальной экспериментальной

проверке [1]. В этом исследовании был применен подход на основе переноса обучения (transfer learning): RNN-модель, предварительно обученная на большой базе данных ChEMBL, была дообучена на очень малом наборе из 25 молекул-агонистов ядерных рецепторов RXR и PPAR. Из сгенерированных кандидатов пять были отобраны для химического синтеза. В результате **четыре из пяти соединений продемонстрировали желаемую биологическую активность** в наномолярном и микромолярном диапазоне, причем одно из соединений показало активность $EC_{50} = 0.06 \mu M$. Эта работа стала первым перспективным применением генеративной модели, завершившим полный цикл от дизайна с помощью ИИ до синтеза и успешной биологической валидации, и доказала практическую ценность RNN-подхода для de novo дизайна лекарств.

1.3 Генеративные модели на основе вариационных автоэнкодеров

Несмотря на успехи RNN, они обладают существенным недостатком: процесс генерации сложно контролировать. Отсутствует явный механизм, позволяющий целенаправленно создавать молекулы с заданными свойствами.

Данное ограничение преодолевается с помощью моделей на основе **вариационных автоэнкодеров (Variational Autoencoder, VAE)**. Архитектура VAE включает в себя две нейронные сети: *энкодер*, который отображает дискретное представление молекулы (например, строку SMILES) в низкоразмерное, непрерывное латентное пространство, и *декодер*, выполняющий обратное преобразование из латентного вектора в исходное представление.

Ключевым преимуществом VAE является способность формировать хорошо структурированное и регулярное латентное пространство. Благодаря вероятностной природе кодирования и специальной регуляризации в функции потерь, VAE обеспечивает непрерывность этого пространства. Это означает, что близкие по значению латентные векторы декодируются в химически схожие структуры, а интерполяция между векторами приводит к валидным промежуточным молекулам.

Такая организация латентного пространства открывает возможность для прямой оптимизации молекулярных свойств. Путем градиентного

восхождения по целевой функции, определенной в этом пространстве, можно находить векторы, соответствующие молекулам с улучшенными характеристиками [4]. Таким образом, VAE реализовали переход от неконтролируемого сэмплирования к управляемому *de novo* дизайну. Базовые реализации VAE, однако, имеют ряд ограничений, что стимулировало разработку более совершенных архитектур, которые будут рассмотрены в следующей главе.

ГЛАВА 2

АНАЛИЗ СОВРЕМЕННЫХ АРХИТЕКТУР И ПОДХОДОВ К ЦЕЛЕВОЙ ГЕНЕРАЦИИ

В данной главе представлен детальный анализ двух доминирующих парадигм в области целевого *de novo* дизайна молекул: подходов, основанных на оптимизации в латентном пространстве гетероэнкодеров и вариационных автоэнкодеров (VAE), и подходов, использующих обучение с подкреплением (Reinforcement Learning, RL) для прямой максимизации целевых свойств. Будут рассмотрены как теоретические основы каждого подхода, так и практические примеры их реализации, включая методы повышения их эффективности и робастности. Завершает главу сравнительный анализ, выявляющий сильные и слабые стороны каждой методологии.

2.1 Гетероэнкодеры и вариационные автоэнкодеры: оптимизация в латентном пространстве

Подходы, основанные на автоэнкодерах, преследуют цель создать непрерывное, низкоразмерное и химически осмысленное «латентное пространство», в котором молекулярные структуры представлены в виде векторов. Оптимизация свойств в этом случае сводится к навигации по латентному пространству для поиска векторов, которые после декодирования преобразуются в молекулы с желаемыми характеристиками.

2.1.1 Теоретические основы: концепция гетероэнкодера и модель ‘Can2Enum’

Стандартные автоэнкодеры, обученные на строковом представлении молекул (SMILES), сталкиваются с фундаментальной «проблемой репрезентации». Поскольку одна и та же молекулярная структура может быть описана множеством различных, но химически эквивалентных SMILES-строк, стандартный автоэнкодер обучается сжимать и восстанавливать не инвариантную структуру молекулы, а особенности конкретной текстовой строки. Это приводит к тому, что разные SMILES-представления одной и той же молекулы отображаются в удаленные точки латентного пространства, делая

его «зашумленным», неструктурированным и непригодным для эффективной навигации [7].

Для решения этой проблемы была предложена концепция химического **гетероэнкодера**. В отличие от стандартного автоэнкодера, который обучается на задаче реконструкции (вход идентичен выходу), гетероэнкодер решает задачу «перевода» между различными, но семантически эквивалентными представлениями одной и той же сущности. В контексте химии это означает, что модель может обучаться, например, переводить каноническую SMILES-строку в одну из множества случайных (enumerated) SMILES-строк. Такая постановочная задача заставляет модель игнорировать синтаксические особенности входной строки и изучать инвариантное, химически релевантное представление молекулы.

Эффективность данного подхода была продемонстрирована на примере модели ‘Can2Enum’ [7]. Стандартный автоэнкодер (‘Can2Can’) показал сильную корреляцию расстояний в латентном пространстве со схожестью текстовых строк (коэффициент детерминации $R^2 = 0.58$) и слабую – со схожестью молекулярных отпечатков ($R^2 = 0.24$). В то же время гетероэнкодер ‘Can2Enum’ (канонический SMILES на входе, случайный на выходе) достиг сбалансированного и химически релевантного пространства, где корреляция с отпечатками достигла $R^2 = 0.58$, а со строками – $R^2 = 0.55$. Латентные векторы, полученные с помощью гетероэнкодеров, также показали себя значительно более качественными признаками для решения задач QSAR, превзойдя как стандартный автоэнкодер, так и классические отпечатки ECFP4 [7].

2.1.2 Пример реализации: гетероэнкодер для дизайна ингибиторов Bcr-Abl

Практическое применение и дальнейшее развитие концепции гетероэнкодера было продемонстрировано в задаче *de novo* дизайна потенциальных ингибиторов Bcr-Abl тирозинкиназы – ключевой мишени в терапии хронического миелоидного лейкоза [9]. В данной работе была разработана и апробирована сложная архитектура условного гетероэнкодера, специально адаптированная для интеграции данных различной природы и целенаправленной генерации молекул с высоким сродством к белковой мишени.

Архитектура модели, детально описанная в работе, представляет собой реализацию мультимодального подхода:

- **Блок кодирования** включает три параллельных энкодера для обработки

разнородных входных данных: два LSTM-энкодера для стандартной и канонической SMILES-строк и один полносвязный энкодер для вектора физико-химических дескрипторов. Такой подход позволяет создать максимально полное представление исходной молекулы.

- **Латентное пространство** формируется путем конкатенации выходных векторов всех трех энкодеров. Ключевой особенностью, превращающей модель в условную, является добавление к этому вектору одного нейрона, отвечающего за целевое значение энергии связывания. Это позволяет в дальнейшем управлять процессом генерации, "заказывая" у модели молекулы с желаемым свойством.
- **Блок декодирования** состоит из двух параллельных LSTM-декодеров, которые обучаются восстанавливать из единого условного латентного вектора как стандартную, так и каноническую SMILES-строки, реализуя принцип multi-task learning.

Модель была обучена на наборе из 108 410 молекул, содержащих скаффолд 2-ариламинопиримидина. В результате последующей генерации и компьютерной валидации методами молекулярного докинга были отобраны четыре соединения-лидера. Эти соединения продемонстрировали предсказанную аффинность, сопоставимую или превосходящую референсный препарат понатиниб. Например, соединение-лидер I показало энергию связывания с нативной формой Bcr-Abl -13.8 ккал/моль, что значительно лучше показателя понатиниба (-12.0 ккал/моль) [9].

Данный кейс наглядно демонстрирует, как архитектура гетероэнкодера может быть успешно адаптирована для решения конкретной задачи в медицинской химии, реализуя полный вычислительный пайплайн от генерации до валидации кандидатов. Ниже, в следующем подразделе, будет представлен детальный анализ практической реализации этой модели на основе ее открытого исходного кода.

2.1.3 Практический анализ реализации: обзор кода и архитектуры

Для глубокого понимания теоретической модели, описанной в предыдущем разделе, был проведен статический анализ ее эталонной реализации, представленной в открытом репозитории Smiles-HeteroEncoder0-CML. Данный анализ позволяет детально рассмотреть практические аспекты построения и обучения модели, а также реконструировать пайплайн обработки данных, объясняя не только последовательность шагов, но и их методологическое обоснование.

2.1.4 Технологический стек.

Проект построен на основе стандартного для задач глубокого обучения и медицинской химии набора библиотек. Роль каждой из них четко определена:

- **tensorflow (версия 2.4.1):** Выступает в качестве основного фреймворка для построения и обучения нейронной сети. Он предоставляет все необходимые высокоуровневые компоненты через Keras API, включая рекуррентные слои (LSTM), полносвязные слои (Dense), а также механизмы для компиляции модели и управления процессом обучения.
- **rdkit-pypi:** Является краеугольным камнем для решения задач медицинской химии. Библиотека играет центральную роль в пайплайне обработки данных, предоставляя инструменты для парсинга SMILES-строк в молекулярные графы (`Chem.MolFromSmiles`), выполнения поиска по подструктуре (`HasSubstructMatch`) для фильтрации по фармакофору и вычисления молекулярных дескрипторов.
- **scikit-learn:** Используется для выполнения классических задач машинного обучения, которые предшествуют и поддерживают основной deep learning пайплайн. В частности, с помощью этой библиотеки решаются задачи разделения выборки на обучающую и тестовую, а также стандартизация числовых признаков (дескрипторов и энергии связывания) с помощью `StandardScaler`, что является обязательным шагом для стабилизации обучения нейронной сети.

2.1.5 Пайплайн обработки данных.

Пайплайн обработки данных, реконструированный на основе анализа кода, включает несколько последовательных этапов, каждый из которых имеет четкое назначение.

- **Первичная фильтрация по длине.** Исходные данные, представленные в виде SMILES-строк и связанных с ними свойств, проходят фильтрацию, в ходе которой отбираются только те молекулы, длина SMILES которых находится в диапазоне от 35 до 75 символов. Цель этого шага – унификация входных последовательностей. Это позволяет уменьшить объем необходимого паддинга (дополнения последовательностей до одинаковой длины) и стабилизировать обучение рекуррентных слоев, которые чувствительны к большой вариативности длин входов.
- **Фокусировка на целевом химическом пространстве.** Далее, с помощью `rdkit`, каждая молекула проверяется на наличие ключевой фармакофорной группы (2-арилпиримидина). Данная операция

позволяет сфокусировать модель на генерации молекул, которые уже содержат структурный мотив, известный своей важностью для целевой биологической активности (ингибирование Bcr-Abl тирозинкиназы).

- **Векторизация SMILES-строк.** Финальным шагом подготовки является преобразование символьных SMILES-строк в числовой формат, понятный нейронной сети. Для этого сначала формируется словарь уникальных символов (токенов), встречающихся в датасете. Этот словарь дополняется специальными токенами: ! для обозначения начала последовательности и E – для ее конца. Затем каждая SMILES-строка преобразуется в числовую матрицу методом One-Hot кодирования. При этом методе каждый символ представляется в виде разреженного бинарного вектора, где все элементы равны нулю, кроме одного, соответствующего индексу символа в словаре. В результате, для батча молекул формируется трехмерный тензор размерностью (batch_size, max_length, vocab_size), полностью готовый для подачи на вход рекуррентной нейронной сети.

2.1.6 Архитектура модели.

Архитектура модели, реализованная с помощью Keras Functional API, в точности соответствует концепции условного гетерозэнкодера. Она состоит из трех параллельных энкодеров, латентного пространства и двух параллельных декодеров.

1. **LSTM-энкодеры для SMILES.** Два идентичных по архитектуре энкодера обрабатывают два различных, но химически эквивалентных представления молекулы: исходную и каноническую SMILES-строки. Каждый энкодер состоит из двух последовательных LSTM-слоев. Их задача – итеративно прочесть последовательность символов и закодировать всю структурную информацию в векторы финальных скрытых состояний (hidden state и cell state). Использование двух энкодеров для разных представлений является формой ансамблирования, что делает латентное представление более робастным и инвариантным к конкретной форме записи SMILES.
2. **Dense-энкодер для дескрипторов.** Полносвязная нейронная сеть обрабатывает вектор числовых молекулярных дескрипторов (например, топологических индексов или фингерпринтов). Архитектура включает несколько Dense-слоев с функцией активации ReLU и слой BatchNormalization. Включение BatchNormalization

имеет критическое значение для стабилизации обучения, так как он нормализует активации между слоями, предотвращая проблему затухания и взрыва градиентов. Этот энкодер извлекает компактное признаковое представление из неструктурных данных о молекуле.

3. **Формирование условного латентного пространства.** Выходные векторы всех трех энкодеров конкатенируются в единый вектор. Этот объединенный вектор пропускается через полносвязный слой-«бутылочное горлышко» (bottleneck). Роль этого слоя заключается в сжатии всей разнородной информации в единое, компактное и информационно насыщенное латентное представление. Для реализации механизма условной генерации к этому латентному вектору добавляется нормализованное значение энергии связывания, подаваемое на отдельный входной нейрон (input_energy). Этот шаг превращает модель в условную: он позволяет в дальнейшем управлять свойствами генерируемых молекул, задавая желаемое значение энергии.
4. **LSTM-декодеры.** Полученный условный латентный вектор преобразуется с помощью Dense-слоев в начальные скрытые состояния для двух параллельных LSTM-декодеров. Каждый декодер решает задачу авторегрессионной генерации последовательности токенов, восстанавливая одно из представлений SMILES (исходное или каноническое). На выходе каждого декодера стоит Dense-слой с функцией активации softmax, которая преобразует выходные логиты в вероятностное распределение по всему словарю символов. Это позволяет на каждом шаге генерации предсказывать наиболее вероятный следующий символ.

2.1.7 Процесс обучения и генерации.

Процесс обучения модели реализован с использованием оптимизатора Adam и функции потерь categorical_crossentropy, которая применяется к каждому токenu генерируемой последовательности. Важной особенностью обучения декодеров является применение стратегии «**Teacher Forcing**». При этой стратегии на вход декодера на каждом временном шаге подается не его собственное предсказание с предыдущего шага, а истинный токен из целевой последовательности. Это значительно стабилизирует и ускоряет обучение, так как предотвращает накопление ошибок на ранних этапах. Для повышения эффективности обучения используется callback ReduceLROnPlateau. Его назначение – динамическая подстройка скорости обучения. Он отслеживает

функцию потерь на валидационной выборке и автоматически снижает скорость обучения, если прогресс останавливается, что позволяет модели более точно «спуститься» в локальный минимум.

Генерация новых молекул (инференс) представляет собой итеративный авторегрессионный процесс.

1. **Инициализация:** Декодер инициализируется латентным вектором, который может быть получен из молекулы-прототипа или сэмплирован из латентного пространства, а также целевым значением энергии.
2. **Старт:** На первом шаге на вход декодера подается стартовый токен (!).
3. **Авторегрессионный цикл:** На каждом последующем шаге модель предсказывает следующий токен на основе своего текущего состояния и входного токена с предыдущего шага. Предсказанный токен добавляется к генерируемой строке и одновременно используется в качестве входа для следующего шага. Этот цикл «предсказал-добавил-подал на вход» продолжается итеративно.
4. **Завершение:** Процесс останавливается, когда модель генерирует стоп-токен (E) или достигается максимальная заданная длина последовательности.

2.1.8 Развитие VAE-подходов: решение проблем и повышение эффективности

Как было показано в предыдущей главе, вариационные автоэнкодеры предоставляют мощный фреймворк для создания непрерывного латентного пространства и генерации молекул. Однако их базовые реализации сталкивались с рядом проблем, что стимулировало разработку более совершенных архитектур.

Одной из главных проблем является **коллапс апостериорного распределения** (*posterior collapse*), при котором декодер обучается игнорировать информацию из латентного пространства и генерирует молекулы, основываясь только на запомненных данных. Для решения этой проблемы была предложена модель PCF-VAE [10]. Ключевой инновацией стала репараметризация функции потерь ELBO путем введения динамического весового коэффициента α для члена KL-дивергенции. Этот коэффициент постепенно увеличивается в ходе обучения (annealing), позволяя модели на ранних этапах сосредоточиться на качественной реконструкции, а затем — на регуляризации латентного пространства. В сочетании с использованием упрощенного синтаксиса GenSMILES это позволило значительно повысить

новизну генерируемых молекул (93.77% у PCF-VAE против 69.49% у стандартного VAE на бенчмарке MOSES).

Следующим шагом стало повышение эффективности **условной генерации**. Модель β -CVAE [11] представила метод явного кодирования свойств в латентное пространство (Explicit Latent Conditioning, ELC). Вместо стандартного априорного распределения $\mathcal{N}(0, I)$, в функции потерь используется условное распределение $\mathcal{N}(\hat{c}, I)$, где $\hat{c}$ – нормализованное значение целевого свойства. Это «встраивает» информацию о свойстве непосредственно в структуру латентного пространства. В сочетании с ПИ-регулятором для коэффициента β , поддерживающим целевой уровень взаимной информации, данный подход позволил достичь прорывных результатов. В задаче безусловной оптимизации пенализированного LogP (pLogP) модель достигла значения 104.29, установив новый state-of-the-art с огромным отрывом от предыдущего лучшего результата (38.57).

Наконец, для повышения **робастности и качества генерации вне распределения** (Out-of-Distribution, OOD) была предложена архитектура Multi-Decoder VAE (MD-VAE) [12]. Она состоит из одного общего энкодера и ансамбля из K декодеров. Для поощрения разнообразия каждый декодер обучается на своем собственном латентном векторе z_k , сэмплированном из одного апостериорного распределения. Ключевой особенностью является коллаборативная функция потерь, которая вычисляется на основе усредненного предсказания всего ансамбля. Этот подход показал систематическое превосходство над базовыми моделями, особенно в OOD-сценарии, где средняя эффективность генерации у MD-VAE составила 47.7%, что является относительным улучшением на 31.4% по сравнению с сильной базовой моделью ControlVAE (36.3%).

Несмотря на успехи строковых моделей, проблема генерации невалидных SMILES остается актуальной. Это привело к развитию графовых VAE, которые работают не с текстовой строкой, а с более естественным графовым представлением молекулы. Одним из наиболее успешных примеров является **Junction Tree VAE (JT-VAE)** [5]. Эта модель оперирует на уровне химически осмысленных строительных блоков (колец и связей), генерируя молекулу в два этапа: сначала создается древовидный каркас из валидных химических «строительных блоков» (колец, связей), а затем эти блоки собираются в итоговый граф, что гарантирует 100% химическую корректность сгенерированных структур [5]. Такой подход позволяет избежать

стадии валидации и сосредоточиться на оптимизации свойств в хорошо структурированном латентном пространстве.

2.2 Обучение с подкреплением (Reinforcement Learning) для прямой оптимизации свойств

Подходы, рассмотренные в предыдущем разделе – вариационные автоэнкодеры и гетероэнкодеры – реализуют не прямой контроль над генерацией. Их общая стратегия заключается в построении качественного латентного пространства и последующей оптимизации внутри него.

Принципиально иной парадигмой целевой генерации является обучение с подкреплением (Reinforcement Learning, RL), которое реализует прямой контроль над свойствами. В отличие от подходов, основанных на оптимизации в латентном пространстве (таких как VAE и гетероэнкодеры), RL-методы не пытаются построить глобальную модель химического пространства, а напрямую обучают генеративную модель (агента) максимизировать целевую функцию (вознаграждение) путем итеративного взаимодействия со «средой» (вычислительной моделью, оценивающей свойства).

2.2.1 Теоретические основы: фреймворк REINVENT

Одним из наиболее известных и широко используемых фреймворков для RL-дизайна молекул является REINVENT [13]. Его работа основана на взаимодействии трех ключевых компонентов:

- **Агент (Agent):** Генеративная модель, как правило, рекуррентная нейронная сеть (RNN) на основе LSTM или Трансформер, которая обучена генерировать молекулы в виде SMILES-строк.
- **Среда (Environment):** Программный модуль, который принимает на вход сгенерированную молекулу и вычисляет для нее скалярную оценку (вознаграждение) в диапазоне от 0 до 1. Среда может включать в себя предсказательные QSAR-модели, расчеты молекулярного докинга, оценку физико-химических свойств и т.д.
- **Вознаграждение (Reward):** Целевая функция, которую агент стремится максимизировать.

Центральным механизмом обучения является оптимизация политики агента с помощью стратегии "Difference between Augmented and Posterior" (DAP).

Функция потерь минимизирует расхождение между правдоподобием молекулы T у текущего агента ($\log P_{\text{agent}}(T)$) и так называемым «дополненным» правдоподобием:

$$\log P_{\text{aug}}(T) = \log P_{\text{prior}}(T) + \sigma S(T)$$

где $P_{\text{prior}}(T)$ – правдоподобие от исходной, предварительно обученной модели (prior), $S(T)$ – итоговая оценка (вознаграждение) молекулы, а σ – гиперпараметр, контролирующий силу оптимизации. Такой подход позволяет агенту генерировать высокооцененные молекулы, не слишком отдаляясь от химически «правдоподобного» пространства, изученного prior-моделью, что предотвращает катастрофическое забывание.

2.2.2 Пример адаптации: REINVENT с GPU-ускорением для поиска ингибиторов ВИЧ-1

Стандартные реализации RL-пайплайнов часто сталкиваются с вычислительным «бутылочным горлышком», когда в качестве среды используется ресурсоемкий молекулярный докинг на CPU. Для решения этой проблемы была предложена адаптация архитектуры REINVENT, в которой стандартный механизм оценки был заменен на высокопроизводительный конвейер с использованием докинга на GPU [14].

Ключевой модификацией стала интеграция программы ‘AutoDock-Vina-GPU-2.1’ непосредственно в цикл обучения RL. На каждом шаге модель генерирует пакет SMILES-строк, которые в реальном времени конвертируются в 3D-структуры и отправляются на GPU-докинг в активный сайт белка-мишени gp120 ВИЧ-1. Для повышения точности предсказаний результаты докинга дополнительно переоценивались с помощью модели машинного обучения ‘RFScore-4’, которая показала значительно лучшую корреляцию с экспериментальными данными (коэффициент Пирсона 0.661 против 0.476 у Vina-GPU).

Функция вознаграждения также была усложнена. Базовое вознаграждение, вычисленное из энергии связывания ΔG , умножалось на штрафные коэффициенты в случае нарушения молекулой ключевых физико-химических свойств (например, правила пяти Липинского). Такой подход направляет генерацию в сторону не просто активных, но и биодоступных соединений. В результате за 60 часов работы на GPU было сгенерировано более 62 000 уникальных молекул, из которых более 34 000 удовлетворили как критерию высокого сродства ($\Delta G < -9.2$ ккал/моль), так и всем

фармакокинетическим ограничениям, став перспективными кандидатами для дальнейших исследований [14].

2.2.3 Повышение эффективности RL: Curriculum Learning и Sample Efficiency

Несмотря на свою гибкость, policy-based RL страдает от двух существенных проблем: неэффективности обучения на сложных задачах и низкой выборочной эффективности при работе с дорогими оракулами.

Для решения первой проблемы был предложен подход **Обучения по Учебному Плану (Curriculum Learning, CL)** [15]. Вместо того чтобы сразу решать сложную многопараметрическую задачу, агент сначала обучается на последовательности упрощенных задач. Например, при оптимизации с использованием докинга, на первом этапе агент может обучаться генерировать молекулы, просто похожие по 2D-структуре на известный лиганд (быстрая оценка), и только после достижения определенного порога в эту задачу добавляется дорогостоящий докинг. Эксперименты показали, что стандартный RL-агент не генерировал продуктивных молекул в течение первых 150-200 эпох, в то время как CL-подход начал делать это практически немедленно, сгенерировав в итоге в 3.7-4.2 раза больше целевых соединений.

Вторую проблему – низкую **выборочную эффективность (sample inefficiency)** – решает алгоритм **Augmented Memory** [16]. Он радикально повышает эффективность использования каждого дорогостоящего вызова оракула за счет комбинации техник «повторения опыта» (experience replay) и «аугментации данных» (SMILES augmentation). Все лучшие найденные молекулы сохраняются в буфере памяти. На каждом шаге обучения агент многократно обновляется на основе всех молекул из этого буфера, причем для каждой молекулы генерируется множество ее эквивалентных SMILES-представлений. Это создает чрезвычайно сильный обучающий сигнал. Данный метод установил новый state-of-the-art на стандартизированном бенчмарке РМО, достигнув AUC Top-10 = 15.002 (против 14.016 у базового REINVENT) и показав способность генерировать в 2-3 раза больше качественных молекул при том же бюджете вызовов оракула.

2.3 Сравнительный анализ подходов к целевой генерации

Подходы, основанные на VAE/гетероэнкодерах и на обучении с подкреплением, представляют две различные философии целевой генерации. VAE-подходы фокусируются на *непрямом* контроле через построение качественного, непрерывного представления химического пространства. Генерация и оптимизация являются вторичными задачами, выполняемыми внутри этого заранее построенного пространства. Качество итоговых молекул напрямую зависит от того, насколько хорошо модель «поняла» и структурировала распределение обучающих данных.

RL-подходы, напротив, реализуют *прямой* контроль. Их единственная цель – максимизировать заданную функцию вознаграждения. Модель напрямую обучается генерировать образцы, которые получают высокий балл, не заботясь о построении глобальной карты химического пространства. Это делает RL чрезвычайно гибким инструментом для многопараметрической оптимизации, но также и более склонным к «эксплуатации» найденных решений, что может приводить к снижению разнообразия (коллапсу мод), если не применять специальные техники.

Ниже приведена сводная таблица, сравнивающая оба подхода по ключевым критериям.

Table 2. Сравнительный анализ подходов к целевой генерации молекул

Критерий	Оптимизация в латентном пространстве	Прямая оптимизация политики
Фундаментальный принцип	Двухэтапный подход: (1) Построение низкоразмерного непрерывного представления (латентного пространства) на основе обучающего набора данных. (2) Последующая оптимизация целевых свойств путем поиска в данном пространстве.	Итеративная оптимизация генеративной модели (политики) с целью максимизации функции вознаграждения. Модель обучается генерировать образцы, соответствующие целевым свойствам, в процессе взаимодействия со средой.

Продолжение на следующей странице

Продолжение таблицы 2

Критерий	Оптимизация в латентном пространстве	Прямая оптимизация политики
Разнообразие генерируемых структур	Высокое. Модель обучается аппроксимировать распределение данных из обучающей выборки, что способствует генерации химически разнообразных структур при сэмплинговании из латентного пространства.	Потенциально низкое. Склонен к эксплуатации найденных решений и коллапсу мод, когда модель генерирует ограниченный набор схожих структур с высоким вознаграждением. Требуется введение специальных механизмов для поддержания разнообразия.
Требования к данным	Требуется крупный и разнообразный набор данных для обучения репрезентативного латентного пространства. Для этапа целевой оптимизации необходим дополнительный набор данных с аннотированными свойствами для обучения прокси-модели.	Обычно используется предобученная на общем корпусе модель. Для целевой оптимизации не требуется специфический набор данных, так как модель обучается в режиме онлайн, генерируя образцы и получая обратную связь от функции вознаграждения.
Гибкость (интеграция новых свойств)	Низкая. Интеграция нового целевого свойства для оптимизации, как правило, требует переобучения прокси-модели или модификации и переобучения основной архитектуры (например, с условным латентным пространством).	Высокая. Новые целевые свойства могут быть легко интегрированы путем добавления новых компонентов в составную функцию вознаграждения без необходимости изменения архитектуры генеративной модели.
Интерпретируемость	Относительно высокая. Структура латентного пространства допускает визуализацию, интерполяцию и анализ, что позволяет исследовать взаимосвязи между структурой молекул и их представлением.	Низкая. Процесс принятия решений генеративной моделью (политикой) трудно интерпретируем. Оптимизация направлена на максимизацию метрики, а не на построение семантически осмысленного представления.

ГЛАВА 3

ОЦЕНКА, ОГРАНИЧЕНИЯ И ПЕРСПЕКТИВЫ РАЗВИТИЯ ГЕНЕРАТИВНЫХ МОДЕЛЕЙ

Анализ ключевых архитектур, представленный в предыдущей главе, демонстрирует значительный прогресс в области генеративного дизайна молекул. Однако само по себе создание новых моделей не является достаточным условием для научного развития. Не менее важными являются стандартизация их оценки, глубокое понимание фундаментальных ограничений существующих подходов и четкое видение перспективных направлений исследований. Данная глава посвящена критическому анализу этих трех аспектов, синтезируя выводы из передовых научных работ и формируя целостную картину текущего состояния и будущего генеративной медицинской химии.

3.1 Стандартизация оценки: бенчмарки и метрики

Одной из центральных проблем, тормозивших развитие области генеративных моделей, было отсутствие единого стандарта для их сравнения. Исследователи использовали различные наборы данных, методы их предобработки и метрики качества, что делало невозможным объективное сравнение эффективности новых архитектур. Это приводило к несопоставимым, зачастую невоспроизводимым результатам и затрудняло оценку реального прогресса. Эта ситуация стимулировала создание специализированных бенчмаркинговых платформ, призванных унифицировать подходы к оценке и обеспечить воспроизводимость результатов. Эволюцию этих платформ можно условно разделить на несколько этапов, отражающих смещение акцентов от абстрактных задач к более прагматичным и релевантным для реальных RD-проектов.

3.1.1 Фундаментальные бенчмарки и обучение на распределении

Первые комплексные платформы были сфокусированы на фундаментальной задаче – способности модели изучать и воспроизводить распределение свойств молекул из обучающего набора данных (distribution learning).

Одним из пионеров в этой области стал бенчмарк GuacaMol [17]. Он предложил четкое разделение задач на оценку воспроизведения распределения и целенаправленную генерацию, представив 20 разнообразных задач по оптимизации свойств. Ключевыми метриками для оценки качества распределения стали валидность (Validity), новизна (Novelty) и расстояние Фреше ChemNet (FCD), измеряющее сходство между распределениями сгенерированных и реальных молекул.

Вскоре после этого появился бенчмарк MOSES (Molecular Sets) [18], который сосредоточился исключительно на задаче обучения распределению. Его ключевым вкладом стало предоставление большого, тщательно отфильтрованного набора данных, комплексного набора метрик и, что особенно важно, введение специального тестового набора на основе скаффолдов, который позволил оценивать способность моделей к генерализации и созданию молекул с новыми химическими каркасами. Эти первые платформы заложили основу для стандартизированной оценки, акцентируя внимание на статистическом качестве генерируемых молекул.

3.1.2 Сдвиг к практической оптимизации

По мере развития области стало очевидно, что способность воспроизводить распределение не всегда коррелирует с эффективностью решения практических задач оптимизации. Многие исследования не учитывали ключевой ресурс в реальной разработке лекарств – количество вызовов оценочной функции («оракула»). Эту проблему решил бенчмарк РМО (Practical Molecular Optimization) [19], который сместил фокус на эффективность выборки (sample efficiency). РМО ограничил бюджет вызовов оракула до 10 000 и ввел метрику AUC top-K, вознаграждающую модели, которые находят молекулы с высокими значениями свойств за меньшее количество попыток.

Дальнейшее углубление в практические аспекты разработки лекарств привело к созданию бенчмарка Lo-Hi [20]. Его авторы справедливо отметили, что существующие подходы смешивают две принципиально разные задачи: поиск новых «хитов» (Hit Identification, Hi) и оптимизацию уже известных структур-«лидеров» (Lead Optimization, Lo). Для имитации этих сценариев были предложены специализированные методы разделения данных: Hi-splitter гарантирует структурное несходство между обучающей и тестовой выборками, а Lo-сплит оценивает способность модели ранжировать близкие аналоги. Этот этап ознаменовал переход от общих задач к более гранулированным и

реалистичным сценариям, отражающим этапы реального RD-цикла.

3.1.3 Гибкость и релевантность для RD

Несмотря на успехи стандартизации, существующие бенчмарки оставались относительно жесткими, предлагая исследователям предопределенный набор задач. Пробел в создании гибких и настраиваемых инструментов для оценки заполнил фреймворк MolScore [21]. В отличие от статичных бенчмарков, MolScore представляет собой модель-агностическую платформу, позволяющую пользователям определять собственные, сложные и практически значимые задачи многопараметрической оптимизации (MPO) через конфигурационные JSON-файлы. Ключевым преимуществом стала интеграция широкого спектра релевантных для дизайна лекарств оценочных функций, включая предсказательные QSAR-модели, оценку синтетической доступности (RAscore) и, что особенно важно, интерфейсы к программам молекулярного докинга. Это позволило формулировать и оценивать задачи, максимально приближенные к реальным проектам, например, оптимизацию селективности или аффинности связывания на основе структуры мишени.

3.1.4 Оценка 3D-генерации

Все вышеупомянутые платформы были ориентированы на оценку моделей, работающих с 2D-представлениями молекул (SMILES, графы). Однако параллельно развивались модели, генерирующие молекулы непосредственно в трехмерном пространстве, что потребовало разработки принципиально новых подходов к оценке. Бенчмарк GenBench3D [22] стал первой комплексной платформой, сфокусированной на оценке качества 3D-генеративных моделей. Ключевым вкладом стала метрика Validity3D, которая оценивает физическую реалистичность сгенерированной конформации (длины связей, валентные углы, отсутствие стерических столкновений) на основе данных из Кембриджской кристаллографической базы данных (CSD). Исследование выявило критическую проблему: большинство моделей генерируют конформационно невалидные структуры, для которых стандартные оценки аффинности, например, оценка докинга, могут быть необоснованно завышены.

В развитие этой темы, комплексное исследование диффузионных 3D-моделей [23] предложило расширенный набор из 25 метрик, включающий детальный анализ геометрических свойств, таких как распределение торсионных углов. Было показано, что производительность моделей значительно падает при переходе от генерации малых и простых молекул

(набор QM9) к более крупным и сложным структурам, характерным для лекарств (набор GEOM-Drugs). Этот последний этап демонстрирует, что фокус в оценке генеративных моделей смещается от химической корректности 2D-графов к обеспечению физической и геометрической правдоподобности 3D-структур, что является необходимым условием для их практического применения в структурно-ориентированном дизайне лекарств.

3.2 Перспективы развития: за пределами RNN и SMILES

Анализ ограничений классических подходов позволяет очертить три магистральных направления, по которым движется современная наука в области генеративного дизайна молекул: переход к более мощным архитектурам, переход к более естественным представлениям данных и, наконец, переход от 2D-структур к 3D-геометрии.

Направление №1: От RNN к Трансформерам и большим языковым моделям. Рекуррентные нейронные сети, долгое время доминировавшие в задачах обработки последовательностей, постепенно уступают место архитектуре Трансформер. Благодаря механизму внимания (attention), трансформеры способны улавливать дальние зависимости в последовательностях, что делает их более мощным инструментом для моделирования сложных SMILES-строк. Эта тенденция нашла отражение в современных фреймворках, таких как **REINVENT 4**, где трансформерная модель была добавлена как опция для задач локальной оптимизации молекул [13]. Последующие работы показали, что обучение с подкреплением (RL) особенно эффективно именно в связке с трансформерами для целенаправленной генерации [24]. Апогеем этого тренда стало появление «фундаментальных моделей» (foundation models), таких как **GP-MOLFORMER**, обученных на миллиардах молекул. Эти модели, заимствуя парадигму из обработки естественного языка (NLP), демонстрируют беспрецедентную универсальность и производительность [25].

Направление №2: От строк к графам. Как было показано ранее, строковые представления являются неестественными для молекул, которые по своей природе являются графами. Поэтому вторым ключевым трендом является все более широкое применение графовых нейронных сетей (GNN).

Модель **JT-VAE** была одним из пионеров этого направления. Обширные обзорные работы подтверждают, что GCN (Graph Convolutional Networks) и другие варианты GNN сегодня являются передовой технологией для широкого спектра задач, от предсказания свойств до de novo генерации, так как они способны извлекать признаки напрямую из топологии молекулы, минуя «бутылочное горлышко» строкового представления [26].

Направление №3: От 2D к 3D. Наиболее передовым и сложным направлением является переход от генерации 2D-графов к генерации полноценных 3D-конформаций молекул. 3D-структура напрямую определяет биологическую активность, и ее моделирование является Святым Граалем вычислительной химии. На этом фронте доминирующим подходом стали **диффузионные модели**. Такие модели, как **GeoDiff**, обучаются обращать процесс постепенного зашумления 3D-координат атомов, генерируя физически правдоподобные и геометрически корректные структуры с соблюдением фундаментальных симметрий [27]. Как и в случае с 2D-моделями, эта бурно развивающаяся область уже столкнулась с необходимостью стандартизации, что привело к появлению комплексных бенчмарков для сравнения 3D-генераторов [23]. Финальным аккордом этого тренда можно считать появление моделей вроде **BindGPT**, которые объединяют в себе все три направления: используют архитектуру трансформера (LLM), работают с единым представлением, объединяющим 2D-граф (SMILES) и 3D-координаты, и интегрируют обучение с подкреплением для целенаправленной генерации молекул с высокой аффинностью к белковой мишени. Это демонстрирует путь к созданию единых, универсальных и мощных инструментов для полностью автоматизированного дизайна лекарств [28].

ЗАКЛЮЧЕНИЕ

В рамках курсового проекта было проведено всестороннее исследование методов представления и генерации молекулярных строк с использованием рекуррентных нейронных сетей и других архитектур глубокого обучения. Работа охватила анализ от базовых концепций, заложивших основу генеративной медицинской химии, до передовых подходов, определяющих современное состояние области, и перспективных направлений ее будущего развития.

В ходе выполнения работы были получены следующие основные результаты в соответствии с поставленными задачами:

1. Проанализированы основы представления молекул для задач машинного обучения. Установлено, что нотация SMILES, благодаря своей текстовой природе, стала стандартом де-факто, позволившим применить мощные модели из области обработки естественного языка. Вместе с тем выявлены ее ключевые недостатки: проблема неканоничности, генерация синтаксически некорректных строк и семантическая неадекватность для представления сложных химических концепций. В работе показано, что эти ограничения стимулировали разработку целого спектра альтернативных подходов, таких как SELFIES, гарантирующий 100% синтаксическую валидность генерируемых строк, и fragSMILES, который переходит на более высокий семантический уровень, оперируя осмысленными молекулярными фрагментами и предлагая надежный механизм кодирования хиральности. В качестве фундаментальной альтернативы проанализировано представление молекул в виде графов. Наконец, рассмотрены негенеративные дескрипторы, в частности молекулярные отпечатки (ECFP4).
2. Рассмотрены базовые генеративные модели. Показано, что рекуррентные нейронные сети (RNN) стали первыми архитектурами, доказавшими принципиальную возможность генерации новых, валидных и химически осмысленных молекул. В свою очередь, вариационные автоэнкодеры (VAE) ввели концепцию непрерывного латентного пространства, что открыло путь к контролируемой генерации и оптимизации свойств молекул путем навигации в этом пространстве.
3. Проведен детальный сравнительный анализ двух основных парадигм

целевой генерации. Подходы на основе VAE и гетероэнкодеров реализуют не прямой контроль через структурирование латентного пространства, что обеспечивает высокое разнообразие генерируемых структур. Методы обучения с подкреплением (RL) осуществляют прямой контроль, напрямую максимизируя целевую функцию (вознаграждение), что обеспечивает исключительную гибкость, но сопряжено с риском «коллапса мод» и требует более сложных техник для поддержания разнообразия.

4. Исследованы проблемы оценки и ограничения существующих подходов. Подчеркнута важность стандартизированных платформ, таких как MOSES, и комплексных метрик (например, FCD) для объективного сравнения моделей. Рассмотрено развитие бенчмарков от оценки качества воспроизведения распределения данных к более прагматичным и гранулированным задачам. Определены ключевые тенденции, которые будут формировать будущее генеративного дизайна молекул:

- **Переход к более мощным архитектурам:** от RNN к Трансформерам и большим языковым моделям (LLM).
- **Переход к более естественным представлениям:** от одномерных строк (SMILES) к графовым нейронным сетям (GNN), работающим напрямую с топологией молекулы.
- **Переход от 2D к 3D:** разработка моделей, способных генерировать не только граф связности, но и пространственную конформацию молекулы, что критически важно для предсказания биологической активности.

Таким образом, все поставленные задачи были выполнены, что позволило в полной мере достичь цели курсового проекта – провести комплексное исследование и анализ методов нейросетевой генерации молекул.

Результаты работы имеют практическую значимость, поскольку представленный анализ и систематизация подходов могут быть использованы специалистами в области медицинской химии и дизайна лекарств для выбора наиболее подходящих инструментов и архитектур при решении задач *de novo* генерации молекул с заданными свойствами.

Дальнейшие исследования в этой области могут быть направлены на практическую реализацию и сравнение моделей, основанных на передовых подходах, таких как диффузионные модели для генерации 3D-структур или гибридные системы, объединяющие преимущества обучения с подкреплением

и структурированных латентных пространств для достижения одновременно гибкой и разнообразной целевой генерации.

Библиографический список

1. De novo design of bioactive small molecules by artificial intelligence / D. Merk [et al.] // *Molecular informatics*. — 2018. — Vol. 37, no. 1/2. — P. 1700153.
2. Advances in de novo drug design: from conventional to machine learning methods / V. D. Mouchlis [et al.] // *International journal of molecular sciences*. — 2021. — Vol. 22, no. 4. — P. 1676.
3. In silico generation of novel, drug-like chemical matter using the LSTM neural network / P. Ertl [et al.] // *arXiv preprint arXiv:1712.07449*. — 2017.
4. *Wigh D. S., Goodman J. M., Lapkin A. A.* A review of molecular representation in the age of machine learning // *Wiley Interdisciplinary Reviews: Computational Molecular Science*. — 2022. — Vol. 12, no. 5. — e1603.
5. Generative model based on junction tree variational autoencoder for HOMO value prediction and molecular optimization / V. Kondratyev [et al.] // *Journal of Cheminformatics*. — 2023. — Vol. 15, no. 1. — P. 11.
6. fragSMILES as a chemical string notation for advanced fragment and chirality representation / F. Mastrolorito [et al.] // *Communications Chemistry*. — 2025. — Vol. 8, no. 1. — P. 26.
7. *Bjerrum E. J., Sattarov B.* Improving chemical autoencoder latent space and molecular de novo generation diversity with heteroencoders // *Biomolecules*. — 2018. — Vol. 8, no. 4. — P. 131.
8. *Bjerrum E. J., Threlfall R.* Molecular generation with recurrent neural networks (RNNs) // *arXiv preprint arXiv:1705.04612*. — 2017.
9. Генеративная нейронная сеть на основе модели гетероэнкодера для de novo дизайна потенциальных противоопухолевых препаратов: применение к Bcr-Abl тирозинкиназе / А. Карпенко [et al.] // *Информатика*. — 2023. — Vol. 20, no. 3. — P. 7–20.
10. *Bhadwal A. S., Kumari M., Kumar A.* PCF-VAE: posterior collapse free variational autoencoder for de novo drug design // *Scientific Reports*. — 2025. — Vol. 15, no. 1. — P. 34152.
11. *Richards R. J., Groener A. M.* Conditional β -VAE for de novo molecular generation // *arXiv preprint arXiv:2205.01592*. — 2022.

12. String-based molecule generation via multi-decoder VAE / K. Kwon [et al.] // ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). — IEEE. 2023. — P. 1–5.
13. Reinvent 4: modern AI-driven generative molecule design / H. H. Loeffler [et al.] // Journal of Cheminformatics. — 2024. — Vol. 16, no. 1. — P. 20.
14. Адаптация архитектуры нейронной сети REINVENT для генерации потенциальных ингибиторов проникновения ВИЧ-1 / Д. Воробьев [et al.] // Информатика. — 2024. — Vol. 21, no. 3. — P. 80–93.
15. Improving de novo molecular design with curriculum learning / J. Guo [et al.] // Nature Machine Intelligence. — 2022. — Vol. 4, no. 6. — P. 555–563.
16. *Guo J., Schwaller P.* Augmented memory: sample-efficient generative molecular design with reinforcement learning // JACS Au. — 2024. — Vol. 4, no. 6. — P. 2160–2172.
17. GuacaMol: benchmarking models for de novo molecular design / N. Brown [et al.] // Journal of chemical information and modeling. — 2019. — Vol. 59, no. 3. — P. 1096–1108.
18. Molecular sets (MOSES): a benchmarking platform for molecular generation models / D. Polykovskiy [et al.] // Frontiers in pharmacology. — 2020. — Vol. 11. — P. 565644.
19. Sample efficiency matters: a benchmark for practical molecular optimization / W. Gao [et al.] // Advances in neural information processing systems. — 2022. — Vol. 35. — P. 21342–21357.
20. *Steshin S.* Lo-hi: Practical ml drug discovery benchmark // Advances in Neural Information Processing Systems. — 2023. — Vol. 36. — P. 64526–64554.
21. MolScore: a scoring, evaluation and benchmarking framework for generative models in de novo drug design / M. Thomas [et al.] // Journal of Cheminformatics. — 2024. — Vol. 16, no. 1. — P. 64.
22. Benchmarking structure-based three-dimensional molecular generative models using GenBench3D: ligand conformation quality matters / B. Baillif [et al.] // arXiv preprint arXiv:2407.04424. — 2024.
23. Comprehensive Benchmark Study of Diffusion-Based 3D Molecular Generation Models / Y. Qin [et al.] // ACS omega. — 2025. — Vol. 10, no. 37. — P. 42760–42775.

24. Evaluation of reinforcement learning in transformer-based molecular design / J. He [et al.] // Journal of Cheminformatics. — 2024. — Vol. 16, no. 1. — P. 95.
25. Gp-molformer: A foundation model for molecular generation / J. Ross [et al.] // Digital Discovery. — 2025. — Vol. 4, no. 10. — P. 2684–2696.
26. Graph convolutional networks for computational drug development and discovery / M. Sun [et al.] // Briefings in bioinformatics. — 2020. — Vol. 21, no. 3. — P. 919–935.
27. Geodiff: A geometric diffusion model for molecular conformation generation / M. Xu [et al.] // arXiv preprint arXiv:2203.02923. — 2022.
28. Bindgpt: A scalable framework for 3d molecular design via language modeling and reinforcement learning / A. Zholus [et al.] // Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 39. — 2025. — P. 26083–26091.