

**МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И
ИНФОРМАТИКИ
Кафедра биомедицинской информатики**

**ИССЛЕДОВАНИЕ МЕТОДОВ ПРЕДСТАВЛЕНИЯ И ГЕНЕРАЦИИ
МОЛЕКУЛЯРНЫХ СТРОК С ИСПОЛЬЗОВАНИЕМ РЕКУРРЕНТНЫХ
НЕЙРОННЫХ СЕТЕЙ**

Курсовой проект

Кондратёнка Владимира Васильевича
обучающегося 3 курса
специальности ”информатика”

Научный руководитель:
старший преподаватель,
А.Д. Карпенко

Минск, 2025

СОДЕРЖАНИЕ

Перечень сокращений и обозначений	3
Введение	5
Глава 1 Теоретические основы и базовые методы генерации молекул	7
1.1 Представление молекулярных структур для задач машинного обучения	7
1.2 Рекуррентные нейронные сети как генеративные модели «химического языка»	9
1.3 Генеративные модели на основе вариационных автоэнкодеров . . .	10
Глава 2 Анализ современных архитектур и подходов к целевой генерации .	13
2.1 Гетероэнкодеры и вариационные автоэнкодеры: оптимизация в латентном пространстве	13
2.2 Обучение с подкреплением (Reinforcement Learning) для прямой оптимизации свойств	20
2.3 Сравнительный анализ подходов к целевой генерации	23
Глава 3 Оценка, ограничения и перспективы развития генеративных моделей	26
3.1 Стандартизация оценки: бенчмарки и метрики	26
3.2 Фундаментальные ограничения строковых представлений	28
3.3 Перспективы развития: за пределами RNN и SMILES	29
Заключение	31
Библиографический список	33

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

AAE	Adversarial Autoencoder (сопоставительный автоэнкодер)
AUC	Area Under the Curve (площадь под кривой)
CL	Curriculum Learning (обучение по учебному плану)
CPU	Central Processing Unit (центральный процессор)
DAP	Difference between Augmented and Posterior
DFT	Density Functional Theory (теория функционала плотности)
ELBO	Evidence Lower Bound (нижняя граница правдоподобия)
ELC	Explicit Latent Conditioning (явное обусловливание латентного пространства)
FCD	Fréchet ChemNet Distance (расстояние Фреше в пространстве ChemNet)
GCN	Graph Convolutional Networks (графовые сверточные сети)
GNN	Graph Neural Networks (графовые нейронные сети)
GPU	Graphics Processing Unit (графический процессор)
GRU	Gated Recurrent Unit (управляемый рекуррентный блок)
InChI	International Chemical Identifier (международный химический идентификатор)
JT-VAE	Junction Tree Variational Autoencoder
LLM	Large Language Model (большая языковая модель)
LogP	Коэффициент распределения октанол-вода
LSTM	Long Short-Term Memory (долгая краткосрочная память)
MD-VAE	Multi-Decoder Variational Autoencoder
MOSES	Molecular Sets
NLP	Natural Language Processing (обработка естественного языка)
OOD	Out-of-Distribution (вне распределения)
pLogP	Penalized LogP (штрафованный LogP)
QSAR	Quantitative Structure-Activity Relationship (количественное соотношение структура-активность)

RL	Reinforcement Learning (обучение с подкреплением)
RNN	Recurrent Neural Network (рекуррентная нейронная сеть)
SA score	Synthetic Accessibility score (оценка синтетической доступности)
SMILES	Simplified Molecular-Input Line-Entry System (упрощенная система представления молекул)
TPSA	Topological Polar Surface Area (топологическая полярная площадь поверхности)
VAE	Variational Autoencoder (вариационный автоэнкодер)
АИ	Искусственный интеллект
ВИЧ	Вирус иммунодефицита человека
ΔG	Энергия связывания Гиббса
EC_{50}	Концентрация полумаксимального эффекта
R^2	Коэффициент детерминации

ВВЕДЕНИЕ

Разработка новых лекарственных препаратов является одной из наиболее сложных и ресурсоемких задач современной науки. Традиционные подходы к дизайну молекул часто связаны с длительным процессом перебора и синтеза кандидатов. В последние годы методы глубокого обучения произвели революцию во многих областях, и хемоинформатика не стала исключением. Применение генеративных моделей, способных изучать закономерности в больших массивах химических данных и создавать новые, химически осмысленные соединения, открывает беспрецедентные возможности для ускорения процесса открытия лекарств [1; 2]. Использование нейронных сетей, в частности рекуррентных (RNN) и архитектур на их основе, позволяет рассматривать молекулярные структуры как своего рода «химический язык», что дает возможность применять для их генерации мощные подходы из области обработки естественного языка [3]. Исследование и совершенствование этих методов является ключевым фактором для создания эффективных инструментов автоматизированного дизайна молекул с заданными биологическими и физико-химическими свойствами.

Несмотря на значительный прогресс, применение генеративных моделей в дизайне лекарств сталкивается с рядом фундаментальных проблем. Во-первых, это проблема адекватного представления молекулярной структуры в формате, понятном для нейронной сети. Линейные нотации, такие как SMILES, удобны, но вносят синтаксические и семантические ограничения, что приводит к генерации невалидных или химически неадекватных структур [4]. Во-вторых, существует проблема управляемости генеративного процесса. Базовые модели способны генерировать разнообразные молекулы, но не позволяют целенаправленно создавать соединения с заранее определенным набором свойств. Решение этой проблемы требует разработки более сложных архитектур, таких как вариационные автоэнкодеры (VAE) и модели на основе обучения с подкреплением (RL), каждая из которых имеет свои сильные и слабые стороны.

- **Объект исследования** – процесс *de novo* дизайна молекулярных структур с помощью методов глубокого обучения.
- **Предмет исследования** – методы представления (в частности, SMILES) и генерации (на основе RNN, VAE и RL) молекулярных строк для

целенаправленного создания химических соединений с желаемыми свойствами.

Целью данной курсовой работы является комплексное исследование и сравнительный анализ современных методов представления и генерации молекулярных строк на основе нейронных сетей для задач целенаправленного дизайна молекул.

Для достижения поставленной цели были определены следующие задачи:

1. Изучить теоретические основы представления молекулярных структур для задач машинного обучения, уделив особое внимание нотации SMILES, ее преимуществам и недостаткам.
2. Рассмотреть базовые архитектуры генеративных моделей, такие как рекуррентные нейронные сети и вариационные автоэнкодеры, и их раннее применение для генерации химических структур.
3. Провести детальный анализ современных подходов к целевой генерации, включая оптимизацию в латентном пространстве (гетероэнкодеры, условные VAE) и методы обучения с подкреплением (RL).
4. Исследовать проблемы стандартизации оценки генеративных моделей, фундаментальные ограничения строковых представлений и определить перспективные направления развития в данной области.

В ходе работы применялись следующие методы: системный анализ научной и технической литературы по темам хемоинформатики и глубокого обучения; сравнительный анализ архитектур нейронных сетей и подходов к целевой генерации; методы статического анализа кода для изучения практических реализаций моделей; обобщение и систематизация данных для формирования целостной картины текущего состояния и перспектив развития области.

Работа носит обзорно-аналитический характер. Ее практическая значимость заключается в систематизации знаний о современных архитектурах и подходах к генеративному дизайну молекул. Представленный анализ может служить теоретической основой для выбора и разработки эффективных вычислительных инструментов для *de novo* создания новых лекарственных препаратов и химических соединений с заданными свойствами.

ГЛАВА 1

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И БАЗОВЫЕ МЕТОДЫ ГЕНЕРАЦИИ МОЛЕКУЛ

Разработка новых лекарственных препаратов с помощью методов глубокого обучения требует решения двух фундаментальных задач: представления сложной молекулярной структуры в формате, понятном для нейронной сети, и создания генеративных моделей, способных оперировать этим представлением для создания новых, химически осмысленных соединений. Данная глава посвящена рассмотрению теоретических основ, лежащих в основе этих процессов. Будет проанализирована линейная нотация SMILES, ставшая стандартом де-факто для представления молекул в виде последовательностей, а также рассмотрены базовые архитектуры, такие как рекуррентные нейронные сети (RNN) и вариационные автоэнкодеры (VAE), которые первыми продемонстрировали свою эффективность в задачах *de novo* дизайна молекул.

1.1 Представление молекулярных структур для задач машинного обучения

Ключевым шагом, позволившим применить методы обработки естественного языка (Natural Language Processing, NLP) к задачам хемоинформатики, стала разработка линейных нотаций для представления молекулярных структур. Наиболее широкое распространение получила система **SMILES (Simplified Molecular-Input Line-Entry System)** — формат, представляющий молекулу в виде строки символов ASCII. Данный подход был разработан с целью создания машиночитаемого, но при этом компактного и интуитивно понятного для человека представления [4].

Принцип кодирования структуры в SMILES основан на наборе простых правил:

- **Атомы** представляются стандартными символами из периодической таблицы (например, C для углерода, N для азота). Атомы в ароматических системах обозначаются строчными буквами (например, бензол кодируется как c1ccccc1).

- **Связи** одинарные подразумеваются по умолчанию. Двойные и тройные связи обозначаются символами = и # соответственно.
- **Ветвления** боковых цепей от основного скелета молекулы заключаются в круглые скобки (). Например, изобутан представляется строкой CC(C)C.
- **Циклы** кодируются путем разрыва одной из связей в цикле. Атомы, соединенные этой связью, помечаются одинаковыми цифровыми индексами. Например, циклогексан можно представить как C1CCCCC1, где цифра 1 указывает на замыкание цикла между первым и последним атомами углерода.

Представление SMILES обладает рядом преимуществ, главным из которых является его совместимость с моделями глубокого обучения. Рассматривая молекулу как «предложение» на «химическом языке», исследователи смогли напрямую применить к задачам дизайна лекарств мощные архитектуры, такие как рекуррентные нейронные сети (RNN) и трансформеры. Кроме того, SMILES-строки компактны и более читаемы для человека по сравнению с другими форматами, такими как таблицы связности (connection tables), что упрощает работу с базами данных [4].

Тем не менее, у данного подхода есть и существенные недостатки. Основной проблемой является **неканоничность**: одна и та же молекула может быть представлена множеством синтаксически корректных SMILES-строк (например, CCO и OCC для этанола). Это усложняет сравнение структур и требует вычислительно затратных процедур канонизации. Другой важный недостаток заключается в том, что генеративные модели, обученные на SMILES, часто производят синтаксически некорректные строки (например, с непарными скобками). Это создает риск того, что модель в первую очередь изучает синтаксис нотации, а не фундаментальные химические закономерности. Наконец, в базовой форме SMILES не кодирует 3D-информацию о конформации молекулы, что является критически важным для многих задач.

Для решения этих проблем были разработаны альтернативные подходы. **InChI (International Chemical Identifier)** генерирует единственную, каноническую строку для любой молекулы, что решает проблему неоднозначности, но его сложная иерархическая структура делает его менее удобным для генеративных моделей. Более фундаментальной альтернативой являются **молекулярные графы**, где атомы представляются узлами, а связи – ребрами. Такое представление является более естественным для молекул,

лишено синтаксических артефактов и по построению не может сгенерировать химически невалидную структуру (например, с «непарной связью»). Однако работа с графовыми данными требует применения специализированных архитектур, таких как графовые нейронные сети.

1.2 Рекуррентные нейронные сети как генеративные модели «химического языка»

Исторически первыми и наиболее влиятельными архитектурами для генерации молекул стали рекуррентные нейронные сети (RNN), в частности их более сложная разновидность – сети с долгой краткосрочной памятью (Long Short-Term Memory, LSTM). Принцип их работы в контексте химии основан на концепции авторегрессионной языковой модели. SMILES-строка разбивается на последовательность токенов (отдельных символов), и модель обучается на каждом шаге предсказывать следующий токен на основе всех предыдущих. В процессе генерации модель, начиная со стартового токена, посимвольно «пишет» новую SMILES-строку, постоянно опираясь на уже сгенерированную часть последовательности [4]. Ранние работы в этой области продемонстрировали высокую эффективность, масштабируемость и, что самое главное, практическую применимость данного подхода.

Одним из первых масштабных исследований, доказавших состоятельность RNN-подхода, стала работа Ertl et al. (2017) [3]. Обучив относительно простую двухслойную LSTM-сеть на 509,000 биоактивных молекул из базы данных ChEMBL, авторы продемонстрировали возможность генерации **одного миллиона химически корректных молекул менее чем за два часа**. Несмотря на то, что только 32% от всех сгенерированных строк оказались валидными, новизна результата была чрезвычайно высока: лишь 0.3% сгенерированных структур совпадали с молекулами из обучающего набора. Ключевым достижением работы стала многоуровневая валидация, которая показала, что распределения физико-химических свойств (молекулярный вес, LogP, TPSA) и оценки синтетической доступности (SA score) у сгенерированных молекул практически идентичны реальным соединениям из ChEMBL. Наиболее убедительным доказательством стало применение QSAR-моделей, которое показало, что новые молекулы имеют сопоставимый с известными лекарствами

потенциал биологической активности.

В то время как работа Ertl et al. продемонстрировала масштабируемость, исследование Bjerrum и Threllfall (2017) [5] было сфокусировано на детальном анализе качества и новизны генерируемых структур. Обучая модель на различных подмножествах базы ZINC («фрагменто-подобные» и «лекарственно-подобные» молекулы), они показали, что RNN способна точно воспроизводить распределения свойств из обучающей выборки. Это доказывает, что модель улавливает скрытые «химические правила», заложенные в данных. Анализ новизны показал, что до **83%** сгенерированных молекул отсутствовали в исходном обучающем наборе, при этом их оценка синтетической доступности (SA score) имела такое же распределение, как и у реальных соединений. Таким образом, было доказано, что модель генерирует не просто валидные, но и химически осмысленные, новые и потенциально синтезируемые структуры.

Кульминацией ранних исследований стала работа, продемонстрировавшая переход от теоретических выкладок к реальной экспериментальной проверке [1]. В этом исследовании был применен подход на основе переноса обучения (transfer learning): RNN-модель, предварительно обученная на большой базе данных ChEMBL, была дообучена на очень малом наборе из 25 молекул-агонистов ядерных рецепторов RXR и PPAR. Из сгенерированных кандидатов пять были отобраны для химического синтеза. В результате **четыре из пяти соединений продемонстрировали желаемую биологическую активность** в наномолярном и микромолярном диапазоне, причем одно из соединений показало активность $EC_{50} = 0.06 \mu M$. Эта работа стала первым перспективным применением генеративной модели, завершившим полный цикл от дизайна с помощью ИИ до синтеза и успешной биологической валидации, и доказала практическую ценность RNN-подхода для de novo дизайна лекарств.

1.3 Генеративные модели на основе вариационных автоэнкодеров

Несмотря на успехи RNN, они обладают существенным недостатком: процесс генерации сложно контролировать. Отсутствует явный механизм, позволяющий целенаправленно создавать молекулы с заданными свойствами.

Для решения этой проблемы были предложены модели на основе **вариационных автоэнкодеров (Variational Autoencoder, VAE)**. VAE состоит из двух частей: энкодера, который сжимает дискретное представление молекулы (например, SMILES) в непрерывный вектор в скрытом (латентном) пространстве, и декодера, который восстанавливает из этого вектора исходную молекулу. Главное преимущество VAE заключается в том, что его латентное пространство является непрерывным и структурированным, что открывает возможность для градиентной оптимизации свойств и интерполяции между известными структурами для создания новых [4].

Однако стандартные VAE сталкиваются с рядом проблем, главной из которых является **коллапс апостериорного распределения (posterior collapse)**. Этот эффект возникает, когда декодер учится игнорировать информацию из латентного пространства и генерирует выходные данные, опираясь только на входные условия, что приводит к потере разнообразия. Для решения этой проблемы в работе, представляющей архитектуру **PCF-VAE** [6], была предложена модифицированная функция потерь. В ней вводится динамический весовой коэффициент α для члена KL-дивергенции, который постепенно увеличивается в процессе обучения (метод «отжига»). Это позволяет модели на ранних этапах сфокусироваться на точности реконструкции, а затем плавно «включать» регуляризацию латентного пространства. В сочетании с использованием более робастной нотации GenSMILES, данный подход позволил достичь на бенчмарке MOSES высокой валидности (98.01%), уникальности (100%) и новизны (93.77%), демонстрируя эффективное решение проблемы коллапса.

Другой важной задачей является создание моделей для условной генерации, то есть создания молекул с заранее определенными свойствами. В работе, описывающей **условный β -VAE** [7], предложен элегантный метод «явного обусловливания латентного пространства» (Explicit Latent Conditioning, ELC). Вместо того чтобы центрировать априорное распределение в латентном пространстве вокруг нуля, модель центрирует его вокруг стандартизированного значения целевого свойства $\hat{c}$, то есть использует распределение $N(\hat{c}, I)$. Это заставляет модель организовывать латентное пространство в соответствии с целевым свойством, группируя молекулы со схожими значениями вместе. Данный подход, реализованный в гибридной архитектуре (Transformer-энкодер и GRU-декодер), показал рекордные результаты в задаче неограниченной оптимизации, сгенерировав молекулу с предсказанным значением penalized

LogP (pLogP) равным **104.29**, что на порядок превосходило предыдущие достижения.

Несмотря на успехи строковых моделей, проблема генерации невалидных SMILES остается актуальной. Это привело к развитию графовых VAE, которые работают не с линейной строкой, а с более естественным графовым представлением молекулы. Одним из наиболее успешных примеров является **Junction Tree VAE (JT-VAE)** [8]. Эта модель оперирует на уровне химически осмысленных строительных блоков (колец и связей), что по построению гарантирует **100% химическую валидность** генерируемых структур. Такой подход позволяет избежать стадии валидации и сосредоточиться на оптимизации свойств в хорошо структурированном латентном пространстве.

ГЛАВА 2

АНАЛИЗ СОВРЕМЕННЫХ АРХИТЕКТУР И ПОДХОДОВ К ЦЕЛЕВОЙ ГЕНЕРАЦИИ

В данной главе представлен детальный анализ двух доминирующих парадигм в области целевого *de novo* дизайна молекул: подходов, основанных на оптимизации в латентном пространстве гетероэнкодеров и вариационных автоэнкодеров (VAE), и подходов, использующих обучение с подкреплением (Reinforcement Learning, RL) для прямой максимизации целевых свойств. Будут рассмотрены как теоретические основы каждого подхода, так и практические примеры их реализации, включая методы повышения их эффективности и робастности. Завершает главу сравнительный анализ, выявляющий сильные и слабые стороны каждой методологии.

2.1 Гетероэнкодеры и вариационные автоэнкодеры: оптимизация в латентном пространстве

Подходы, основанные на автоэнкодерах, преследуют цель создать непрерывное, низкоразмерное и химически осмысленное «латентное пространство», в котором молекулярные структуры представлены в виде векторов. Оптимизация свойств в этом случае сводится к навигации по латентному пространству для поиска векторов, которые после декодирования преобразуются в молекулы с желаемыми характеристиками.

2.1.1 Теоретические основы: концепция гетероэнкодера

Стандартные автоэнкодеры, обученные на строковом представлении молекул (SMILES), сталкиваются с фундаментальной «проблемой репрезентации». Поскольку одна и та же молекулярная структура может быть описана множеством различных, но химически эквивалентных SMILES-строк, стандартный автоэнкодер обучается сжимать и восстанавливать не инвариантную структуру молекулы, а особенности конкретной текстовой строки. Это приводит к тому, что разные SMILES-представления одной и той же молекулы отображаются в удаленные точки латентного пространства, делая его «зашумленным», неструктурированным и непригодным для эффективной

навигации [9].

Для решения этой проблемы была предложена концепция химического **гетероэнкодера**. В отличие от стандартного автоэнкодера, который обучается на задаче реконструкции (вход идентичен выходу), гетероэнкодер решает задачу «перевода» между различными, но семантически эквивалентными представлениями одной и той же сущности. В контексте химии это означает, что модель может обучаться, например, переводить каноническую SMILES-строку в одну из множества случайных (enumerated) SMILES-строк. Такая постановочная задача заставляет модель игнорировать синтаксические особенности входной строки и изучать инвариантное, химически релевантное представление молекулы.

Эффективность данного подхода была продемонстрирована количественно. Стандартный автоэнкодер ('Can2Can') показал сильную корреляцию расстояний в латентном пространстве со схожестью текстовых строк (коэффициент детерминации $R^2 = 0.58$) и слабую – со схожестью молекулярных отпечатков ($R^2 = 0.24$). В то же время гетероэнкодер 'Can2Enum' (канонический SMILES на входе, случайный на выходе) достиг сбалансированного и химически релевантного пространства, где корреляция с отпечатками достигла $R^2 = 0.58$, а со строками – $R^2 = 0.55$. Латентные векторы, полученные с помощью гетероэнкодеров, также показали себя значительно более качественными признаками для решения задач QSAR, превзойдя как стандартный автоэнкодер, так и классические отпечатки ECFP4 [9].

2.1.2 Пример реализации: гетероэнкодер для дизайна ингибиторов Bcr-Abl

Практическое применение и дальнейшее развитие концепции гетероэнкодера было продемонстрировано в задаче *de novo* дизайна потенциальных ингибиторов Bcr-Abl тирозинкиназы — ключевой мишени в терапии хронического миелоидного лейкоза [10]. В данной работе была разработана и апробирована сложная архитектура условного гетероэнкодера, специально адаптированная для интеграции данных различной природы и целенаправленной генерации молекул с высоким сродством к белковой мишени.

Архитектура модели, детально описанная в работе, представляет собой реализацию мультимодального подхода:

- **Блок кодирования** включает три параллельных энкодера для обработки разнородных входных данных: два LSTM-энкодера для стандартной и

канонической SMILES-строк и один полносвязный энкодер для вектора физико-химических дескрипторов. Такой подход позволяет создать максимально полное представление исходной молекулы.

- **Латентное пространство** формируется путем конкатенации выходных векторов всех трех энкодеров. Ключевой особенностью, превращающей модель в условную, является добавление к этому вектору одного нейрона, отвечающего за целевое значение энергии связывания. Это позволяет в дальнейшем управлять процессом генерации, "заказывая" у модели молекулы с желаемым свойством.
- **Блок декодирования** состоит из двух параллельных LSTM-декодеров, которые обучаются восстанавливать из единого условного латентного вектора как стандартную, так и каноническую SMILES-строки, реализуя принцип multi-task learning.

Модель была обучена на наборе из 108 410 молекул, содержащих скаффолд 2-ариламинопиримидина. В результате последующей генерации и компьютерной валидации методами молекулярного докинга были отобраны четыре соединения-лидера. Эти соединения продемонстрировали предсказанную аффинность, сопоставимую или превосходящую референсный препарат понатиниб. Например, соединение-лидер I показало энергию связывания с нативной формой Bcr-Abl -13.8 ккал/моль, что значительно лучше показателя понатиниба (-12.0 ккал/моль) [10].

Данный кейс наглядно демонстрирует, как архитектура гетероэнкодера может быть успешно адаптирована для решения конкретной задачи в медицинской химии, реализуя полный вычислительный пайплайн от генерации до валидации кандидатов. Ниже, в следующем подразделе, будет представлен детальный анализ практической реализации этой модели на основе ее открытого исходного кода.

2.1.3 Практический анализ реализации: обзор кода и архитектуры

Для глубокого понимания теоретической модели, описанной в предыдущем разделе, был проведен статический анализ ее эталонной реализации, представленной в открытом репозитории Smiles-HeteroEncoder0-CML. Данный анализ позволяет детально рассмотреть практические аспекты построения и обучения модели, а также реконструировать пайплайн обработки данных, объясняя не только последовательность шагов, но и их методологическое обоснование.

2.1.4 Технологический стек.

Проект построен на основе стандартного для задач глубокого обучения и хемоинформатики набора библиотек. Роль каждой из них четко определена:

- **tensorflow (версия 2.4.1):** Выступает в качестве основного фреймворка для построения и обучения нейронной сети. Он предоставляет все необходимые высокоуровневые компоненты через Keras API, включая рекуррентные слои (LSTM), полносвязные слои (Dense), а также механизмы для компиляции модели и управления процессом обучения.
- **rdkit-pypi:** Является краеугольным камнем для решения хемоинформатических задач. Библиотека играет центральную роль в пайплайне обработки данных, предоставляя инструменты для парсинга SMILES-строк в молекулярные графы (Chem.MolFromSmiles), выполнения поиска по подструктуре (HasSubstructMatch) для фильтрации по фармакофору и вычисления молекулярных дескрипторов.
- **scikit-learn:** Используется для выполнения классических задач машинного обучения, которые предшествуют и поддерживают основной deep learning пайплайн. В частности, с помощью этой библиотеки решаются задачи разделения выборки на обучающую и тестовую, а также стандартизация числовых признаков (дескрипторов и энергии связывания) с помощью StandardScaler, что является обязательным шагом для стабилизации обучения нейронной сети.

2.1.5 Пайплайн обработки данных.

Пайплайн обработки данных, реконструированный на основе анализа кода, включает несколько последовательных этапов, каждый из которых имеет четкое назначение.

- **Первичная фильтрация по длине.** Исходные данные, представленные в виде SMILES-строк и связанных с ними свойств, проходят фильтрацию, в ходе которой отбираются только те молекулы, длина SMILES которых находится в диапазоне от 35 до 75 символов. Цель этого шага – унификация входных последовательностей. Это позволяет уменьшить объем необходимого паддинга (дополнения последовательностей до одинаковой длины) и стабилизировать обучение рекуррентных слоев, которые чувствительны к большой вариативности длин входов.
- **Фокусировка на целевом химическом пространстве.** Далее, с помощью rdkit, каждая молекула проверяется на наличие ключевой фармакофорной группы (2-арилпиримидина). Данная операция

позволяет сфокусировать модель на генерации молекул, которые уже содержат структурный мотив, известный своей важностью для целевой биологической активности (ингибирование Bcr-Abl тирозинкиназы).

- **Векторизация SMILES-строк.** Финальным шагом подготовки является преобразование символьных SMILES-строк в числовой формат, понятный нейронной сети. Для этого сначала формируется словарь уникальных символов (токенов), встречающихся в датасете. Этот словарь дополняется специальными токенами: ! для обозначения начала последовательности и E – для ее конца. Затем каждая SMILES-строка преобразуется в числовую матрицу методом One-Hot кодирования. При этом методе каждый символ представляется в виде разреженного бинарного вектора, где все элементы равны нулю, кроме одного, соответствующего индексу символа в словаре. В результате, для батча молекул формируется трехмерный тензор размерностью (batch_size, max_length, vocab_size), полностью готовый для подачи на вход рекуррентной нейронной сети.

2.1.6 Архитектура модели.

Архитектура модели, реализованная с помощью Keras Functional API, в точности соответствует концепции условного гетерозэнкодера. Она состоит из трех параллельных энкодеров, латентного пространства и двух параллельных декодеров.

1. **LSTM-энкодеры для SMILES.** Два идентичных по архитектуре энкодера обрабатывают два различных, но химически эквивалентных представления молекулы: исходную и каноническую SMILES-строки. Каждый энкодер состоит из двух последовательных LSTM-слоев. Их задача – итеративно прочесть последовательность символов и закодировать всю структурную информацию в векторы финальных скрытых состояний (hidden state и cell state). Использование двух энкодеров для разных представлений является формой ансамблирования, что делает латентное представление более робастным и инвариантным к конкретной форме записи SMILES.
2. **Dense-энкодер для дескрипторов.** Полносвязная нейронная сеть обрабатывает вектор числовых молекулярных дескрипторов (например, топологических индексов или фингерпринтов). Архитектура включает несколько Dense-слоев с функцией активации ReLU и слой BatchNormalization. Включение BatchNormalization

имеет критическое значение для стабилизации обучения, так как он нормализует активации между слоями, предотвращая проблему затухания и взрыва градиентов. Этот энкодер извлекает компактное признаковое представление из неструктурных данных о молекуле.

3. **Формирование условного латентного пространства.** Выходные векторы всех трех энкодеров конкатенируются в единый вектор. Этот объединенный вектор пропускается через полносвязный слой-«бутылочное горлышко» (bottleneck). Роль этого слоя заключается в сжатии всей разнородной информации в единое, компактное и информационно насыщенное латентное представление. Для реализации механизма условной генерации к этому латентному вектору добавляется нормализованное значение энергии связывания, подаваемое на отдельный входной нейрон (input_energy). Этот шаг превращает модель в условную: он позволяет в дальнейшем управлять свойствами генерируемых молекул, задавая желаемое значение энергии.
4. **LSTM-декодеры.** Полученный условный латентный вектор преобразуется с помощью Dense-слоев в начальные скрытые состояния для двух параллельных LSTM-декодеров. Каждый декодер решает задачу авторегрессионной генерации последовательности токенов, восстанавливая одно из представлений SMILES (исходное или каноническое). На выходе каждого декодера стоит Dense-слой с функцией активации softmax, которая преобразует выходные логиты в вероятностное распределение по всему словарю символов. Это позволяет на каждом шаге генерации предсказывать наиболее вероятный следующий символ.

2.1.7 Процесс обучения и генерации.

Процесс обучения модели реализован с использованием оптимизатора Adam и функции потерь categorical_crossentropy, которая применяется к каждому токenu генерируемой последовательности. Важной особенностью обучения декодеров является применение стратегии «**Teacher Forcing**». При этой стратегии на вход декодера на каждом временном шаге подается не его собственное предсказание с предыдущего шага, а истинный токен из целевой последовательности. Это значительно стабилизирует и ускоряет обучение, так как предотвращает накопление ошибок на ранних этапах. Для повышения эффективности обучения используется callback ReduceLROnPlateau. Его назначение – динамическая подстройка скорости обучения. Он отслеживает

функцию потерь на валидационной выборке и автоматически снижает скорость обучения, если прогресс останавливается, что позволяет модели более точно «спуститься» в локальный минимум.

Генерация новых молекул (инференс) представляет собой итеративный авторегрессионный процесс.

1. **Инициализация:** Декодер инициализируется латентным вектором, который может быть получен из молекулы-прототипа или сэмплирован из латентного пространства, а также целевым значением энергии.
2. **Старт:** На первом шаге на вход декодера подается стартовый токен (!).
3. **Авторегрессионный цикл:** На каждом последующем шаге модель предсказывает следующий токен на основе своего текущего состояния и входного токена с предыдущего шага. Предсказанный токен добавляется к генерируемой строке и одновременно используется в качестве входа для следующего шага. Этот цикл «предсказал-добавил-подал на вход» продолжается итеративно.
4. **Завершение:** Процесс останавливается, когда модель генерирует стоп-токен (E) или достигается максимальная заданная длина последовательности.

2.1.8 Развитие VAE-подходов: решение проблем и повышение эффективности

Вариационные автоэнкодеры (VAE), являясь вероятностной версией автоэнкодеров, стали основным инструментом для генерации молекул. Однако их базовые реализации сталкивались с рядом проблем, что стимулировало разработку более совершенных архитектур.

Одной из главных проблем является **коллапс апостериорного распределения** (*posterior collapse*), при котором декодер обучается игнорировать информацию из латентного пространства и генерирует молекулы, основываясь только на запомненных данных. Для решения этой проблемы была предложена модель PCF-VAE [6]. Ключевой инновацией стала репараметризация функции потерь ELBO путем введения динамического весового коэффициента α для члена KL-дивергенции. Этот коэффициент постепенно увеличивается в ходе обучения (annealing), позволяя модели на ранних этапах сосредоточиться на качественной реконструкции, а затем – на регуляризации латентного пространства. В сочетании с использованием упрощенного синтаксиса GenSMILES это позволило значительно повысить новизну генерируемых молекул (93.77% у PCF-VAE против 69.49% у

стандартного VAE на бенчмарке MOSES).

Следующим шагом стало повышение эффективности **условной генерации**. Модель β -CVAE [7] представила элегантный метод явного кодирования свойств в латентное пространство (Explicit Latent Conditioning, ELC). Вместо стандартного априорного распределения $\mathcal{N}(0, I)$, в функции потерь используется условное распределение $\mathcal{N}(\hat{c}, I)$, где $\hat{c}$ – нормализованное значение целевого свойства. Это «встраивает» информацию о свойстве непосредственно в структуру латентного пространства. В сочетании с ПИ-регулятором для коэффициента β , поддерживающим целевой уровень взаимной информации, данный подход позволил достичь прорывных результатов. В задаче безусловной оптимизации пенализированного LogP (pLogP) модель достигла значения 104.29, установив новый state-of-the-art с огромным отрывом от предыдущего лучшего результата (38.57).

Наконец, для повышения **робастности и качества генерации вне распределения** (Out-of-Distribution, OOD) была предложена архитектура Multi-Decoder VAE (MD-VAE) [11]. Она состоит из одного общего энкодера и ансамбля из K декодеров. Для поощрения разнообразия каждый декодер обучается на своем собственном латентном векторе z_k , сэмплированном из одного апостериорного распределения. Ключевой особенностью является коллаборативная функция потерь, которая вычисляется на основе усредненного предсказания всего ансамбля. Этот подход показал систематическое превосходство над базовыми моделями, особенно в OOD-сценарии, где средняя эффективность генерации у MD-VAE составила 47.7%, что является относительным улучшением на 31.4% по сравнению с сильной базовой моделью ControlVAE (36.3%).

2.2 Обучение с подкреплением (Reinforcement Learning) для прямой оптимизации свойств

Альтернативной парадигмой целевой генерации является обучение с подкреплением (RL). В отличие от VAE, RL-подходы не пытаются построить гладкое латентное пространство, а напрямую обучают генеративную модель (агента) максимизировать некоторую целевую функцию (вознаграждение) путем итеративного взаимодействия со «средой» (вычислительной моделью,

оценивающей свойства).

2.2.1 Теоретические основы: фреймворк REINVENT

Одним из наиболее известных и широко используемых фреймворков для RL-дизайна молекул является REINVENT [12]. Его работа основана на взаимодействии трех ключевых компонентов:

- **Агент (Agent):** Генеративная модель, как правило, рекуррентная нейронная сеть (RNN) на основе LSTM или Трансформер, которая обучена генерировать молекулы в виде SMILES-строк.
- **Среда (Environment):** Программный модуль, который принимает на вход сгенерированную молекулу и вычисляет для нее скалярную оценку (вознаграждение) в диапазоне от 0 до 1. Среда может включать в себя предсказательные QSAR-модели, расчеты молекулярного докинга, оценку физико-химических свойств и т.д.
- **Вознаграждение (Reward):** Целевая функция, которую агент стремится максимизировать.

Центральным механизмом обучения является оптимизация политики агента с помощью стратегии "Difference between Augmented and Posterior" (DAP). Функция потерь минимизирует расхождение между правдоподобием молекулы T у текущего агента ($\log P_{\text{agent}}(T)$) и так называемым «дополненным» правдоподобием:

$$\log P_{\text{aug}}(T) = \log P_{\text{prior}}(T) + \sigma S(T)$$

где $P_{\text{prior}}(T)$ – правдоподобие от исходной, предварительно обученной модели (prior), $S(T)$ – итоговая оценка (вознаграждение) молекулы, а σ – гиперпараметр, контролирующий силу оптимизации. Такой подход позволяет агенту генерировать высокооцененные молекулы, не слишком отдаляясь от химически «правдоподобного» пространства, изученного prior-моделью, что предотвращает катастрофическое забывание.

2.2.2 Пример адаптации: REINVENT с GPU-ускорением для поиска ингибиторов ВИЧ-1

Стандартные реализации RL-пайплайнов часто сталкиваются с вычислительным «бутылочным горлышком», когда в качестве среды используется ресурсоемкий молекулярный докинг на CPU. Для решения этой проблемы была предложена адаптация архитектуры REINVENT, в которой стандартный механизм оценки был заменен на высокопроизводительный конвейер с использованием докинга на GPU [13].

Ключевой модификацией стала интеграция программы ‘AutoDock-Vina-GPU-2.1’ непосредственно в цикл обучения RL. На каждом шаге модель генерирует пакет SMILES-строк, которые в реальном времени конвертируются в 3D-структуры и отправляются на GPU-докинг в активный сайт белка-мишени gp120 ВИЧ-1. Для повышения точности предсказаний результаты докинга дополнительно переоценивались с помощью модели машинного обучения ‘RFScore-4’, которая показала значительно лучшую корреляцию с экспериментальными данными (коэффициент Пирсона 0.661 против 0.476 у Vina-GPU).

Функция вознаграждения также была усложнена. Базовое вознаграждение, вычисленное из энергии связывания ΔG , умножалось на штрафные коэффициенты в случае нарушения молекулой ключевых физико-химических свойств (например, правила пяти Липинского). Такой подход направляет генерацию в сторону не просто активных, но и биодоступных соединений. В результате за 60 часов работы на GPU было сгенерировано более 62 000 уникальных молекул, из которых более 34 000 удовлетворили как критерию высокого сродства ($\Delta G < -9.2$ ккал/моль), так и всем фармакокинетическим ограничениям, став перспективными кандидатами для дальнейших исследований [13].

2.2.3 Повышение эффективности RL: Curriculum Learning и Sample Efficiency

Несмотря на свою гибкость, policy-based RL страдает от двух существенных проблем: неэффективности обучения на сложных задачах и низкой выборочной эффективности при работе с дорогими оракулами.

Для решения первой проблемы был предложен подход **Обучения по Учебному Плану (Curriculum Learning, CL)** [14]. Вместо того чтобы сразу решать сложную многопараметрическую задачу, агент сначала обучается на последовательности упрощенных задач. Например, при оптимизации с использованием докинга, на первом этапе агент может обучаться генерировать молекулы, просто похожие по 2D-структуре на известный лиганд (быстрая оценка), и только после достижения определенного порога в эту задачу добавляется дорогостоящий докинг. Эксперименты показали, что стандартный RL-агент не генерировал продуктивных молекул в течение первых 150-200 эпох, в то время как CL-подход начал делать это практически немедленно, сгенерировав в итоге в 3.7-4.2 раза больше целевых соединений.

Вторую проблему – низкую **выборочную эффективность (sample**

inefficiency) – решает алгоритм **Augmented Memory** [15]. Он радикально повышает эффективность использования каждого дорогостоящего вызова оракула за счет комбинации техник «повторения опыта» (experience replay) и «аугментации данных» (SMILES augmentation). Все лучшие найденные молекулы сохраняются в буфере памяти. На каждом шаге обучения агент многократно обновляется на основе всех молекул из этого буфера, причем для каждой молекулы генерируется множество ее эквивалентных SMILES-представлений. Это создает чрезвычайно сильный обучающий сигнал. Данный метод установил новый state-of-the-art на стандартизированном бенчмарке PMO, достигнув AUC Top-10 = 15.002 (против 14.016 у базового REINVENT) и показав способность генерировать в 2-3 раза больше качественных молекул при том же бюджете вызовов оракула.

2.3 Сравнительный анализ подходов к целевой генерации

Подходы, основанные на VAE/гетерознкодерах и на обучении с подкреплением, представляют две различные философии целевой генерации. VAE-подходы фокусируются на *непрямом* контроле через построение качественного, непрерывного представления химического пространства. Генерация и оптимизация являются вторичными задачами, выполняемыми внутри этого заранее построенного пространства. Качество итоговых молекул напрямую зависит от того, насколько хорошо модель «поняла» и структурировала распределение обучающих данных.

RL-подходы, напротив, реализуют *прямой* контроль. Их единственная цель – максимизировать заданную функцию вознаграждения. Модель напрямую обучается генерировать образцы, которые получают высокий балл, не заботясь о построении глобальной карты химического пространства. Это делает RL чрезвычайно гибким инструментом для многопараметрической оптимизации, но также и более склонным к «эксплуатации» найденных решений, что может приводить к снижению разнообразия (коллапсу мод), если не применять специальные техники.

Ниже приведена сводная таблица, сравнивающая оба подхода по ключевым критериям.

Table 2. Сравнительный анализ подходов к целевой генерации молекул

Критерий	VAE / Гетероэнкодер	Reinforcement Learning (REINVENT)
Принцип контроля	Непрямой контроль через структуру латентного пространства. Оптимизация выполняется путем навигации (например, градиентного спуска) в этом пространстве к областям, соответствующим желаемым свойствам.	Прямой контроль через явную функцию вознаграждения (reward function). Модель (агент) напрямую обучается генерировать молекулы, максимизирующие эту функцию.
Разнообразие	Метод естественно генерирует разнообразные и химически правдоподобные структуры, исследуя выученное многообразие. Разнообразие является неотъемлемым свойством хорошо обученного латентного пространства.	Склонен к «эксплуатации» и может страдать от «коллапса мод», когда агент начинает генерировать только несколько очень похожих высокооцененных структур. Требуются специальные техники (например, Selective Memory Purge в Augmented Memory) для поддержания разнообразия.
Требования к данным	Для обучения качественного и репрезентативного латентного пространства требуется большой (сотни тысяч молекул) и разнообразный набор данных.	Можно стартовать с предобученной на общем корпусе модели (prior) и дообучаться (fine-tuning) для конкретной задачи, что требует значительно меньшего количества итераций и специфичных данных.

Продолжение на следующей странице

Продолжение таблицы 2

Критерий	VAE / Гетероэнкодер	Reinforcement Learning (REINVENT)
Вычислительная сложность	Обучение VAE является вычислительно затратным процессом. Однако после обучения генерация новых молекул и оптимизация в латентном пространстве происходят очень быстро.	Каждый шаг RL-оптимизации требует вызова «среды» для оценки сгенерированных молекул. Если среда включает дорогостоящие расчеты (докинг, DFT), каждый шаг обучения может быть очень медленным.
Гибкость (новые свойства)	Введение новых свойств для оптимизации часто является нетривиальной задачей. Это может потребовать переобучения модели или использования сложных условных архитектур (Conditional VAE) для структурирования латентного пространства по новому свойству.	Чрезвычайно высокая гибкость. Новые свойства могут быть легко добавлены «на лету» как новый компонент в составную функцию вознаграждения без необходимости изменения архитектуры или переобучения с нуля.

ГЛАВА 3

ОЦЕНКА, ОГРАНИЧЕНИЯ И ПЕРСПЕКТИВЫ РАЗВИТИЯ ГЕНЕРАТИВНЫХ МОДЕЛЕЙ

Анализ ключевых архитектур, представленный в предыдущей главе, демонстрирует значительный прогресс в области генеративного дизайна молекул. Однако само по себе создание новых моделей не является достаточным условием для научного развития. Не менее важными являются стандартизация их оценки, глубокое понимание фундаментальных ограничений существующих подходов и четкое видение перспективных направлений исследований. Данная глава посвящена критическому анализу этих трех аспектов, синтезируя выводы из передовых научных работ и формируя целостную картину текущего состояния и будущего генеративной хемоинформатики.

3.1 Стандартизация оценки: бенчмарки и метрики

Одной из центральных проблем, тормозивших развитие области генеративных моделей, было отсутствие единого стандарта для их сравнения. Исследователи использовали различные наборы данных, методы их предобработки и метрики качества, что делало невозможным объективное сравнение эффективности новых архитектур по принципу «яблоки с яблоками». Это приводило к несопоставимым, зачастую невоспроизводимым результатам и затрудняло оценку реального прогресса [16].

Ответом на этот вызов стала разработка комплексной платформы с открытым исходным кодом MOSES (Molecular Sets) [16]. Данная платформа не просто предложила новый метод, а создала инфраструктуру для стандартизированного обучения и оценки, состоящую из трех ключевых компонентов:

1. **Стандартизированный набор данных.** Авторы MOSES тщательно отфильтровали коллекцию ZINC Clean Leads, создав датасет с четко определенным разделением на обучающую, тестовую и, что особенно важно, *scaffold test* выборки. Последняя содержит молекулы с структурными каркасами, отсутствующими в обучающей выборке,

что позволяет оценить способность модели к генерализации и созданию принципиально новых химических структур.

2. **Реализация базовых моделей.** Платформа включает эталонные реализации нескольких ключевых архитектур (CharRNN, VAE, AAE, JTN-VAE), которые служат «точкой отсчета» (reference point) для всех будущих моделей.
3. **Комплексный набор метрик.** MOSES формализовал и популяризовал набор метрик для всесторонней оценки генеративных моделей, который впоследствии стал стандартом де-факто в большинстве последующих работ [2; 17].

Ключевые метрики, предложенные в MOSES, можно разделить на несколько категорий. Базовые метрики качества генерации включают:

- **Validity (Валидность):** Процент сгенерированных строк (например, SMILES), которые являются синтаксически и семантически корректными и могут быть преобразованы в валидную химическую структуру.
- **Uniqueness (Уникальность):** Процент уникальных молекул среди всех валидных сгенерированных. Низкое значение этого показателя может свидетельствовать о коллапсе мод (mode collapse), когда модель генерирует лишь небольшое подмножество известных ей структур.
- **Novelty (Новизна):** Процент уникальных валидных молекул, отсутствующих в обучающем наборе данных. Эта метрика напрямую измеряет способность модели создавать новые, ранее не виденные соединения.
- **Internal Diversity (IntDiv, Внутреннее разнообразие):** Среднее попарное несходство (обычно 1 - Tanimoto similarity) молекул внутри сгенерированного набора. Высокое значение указывает на то, что модель генерирует химически разнообразные структуры.

Однако наиболее важным вкладом MOSES стала популяризация метрик, оценивающих сходство распределений. Среди них центральное место занимает

3.2 Фундаментальные ограничения строковых представлений

Несмотря на популярность и удобство, строковые представления молекул, в первую очередь SMILES, накладывают серьезные фундаментальные ограничения на генеративные модели. Эти ограничения можно разделить на две категории: синтаксические и семантические.

Первая проблема – **синтаксическая корректность**. Модели, работающие на символьном уровне, такие как RNN, генерируют SMILES-строку символ за символом, пытаясь выучить сложную «грамматику» этого языка. Однако этот процесс часто приводит к генерации синтаксически некорректных строк, которые не соответствуют ни одной реальной молекуле. Эта проблема привела к разработке подходов, которые работают не со строками, а напрямую с графовой структурой молекул. Ярким примером является **Junction Tree Variational Autoencoder (JT-VAE)** [18]. Эта модель решает проблему валидности «по построению». Вместо генерации атомов, JT-VAE оперирует химически осмысленными строительными блоками (кольцами, простыми связями). Генерация происходит в два этапа: сначала создается древовидный каркас из этих блоков, а затем они собираются в итоговый молекулярный граф. Поскольку на каждом шаге используются только валидные химические компоненты, все сгенерированные молекулы гарантированно являются 100% химически корректными.

Вторая, более глубокая проблема – **семантическая неадекватность**. SMILES представляет молекулу на уровне «букв» (атомов), в то время как химики мыслят на уровне «слов» (функциональных групп, фрагментов). Кроме того, SMILES имеет серьезные проблемы с однозначным и инвариантным представлением хиральности – ключевого свойства для биологической активности. Небольшие изменения в порядке обхода графа могут кардинально изменить SMILES-строку и представление стереоцентров. Эту проблему решает нотация **fragSMILES** [19]. Она представляет собой принципиальный переход от атомно-уровневого представления к фрагментному. Молекула сначала декомпозируется на химически осмысленные фрагменты, которые и становятся токенами («словами») в новой строке. Информация о хиральности кодируется явно и привязывается к точкам соединения фрагментов, что делает ее инвариантной к порядку обхода. Эксперименты показывают, что модели, обученные на fragSMILES, генерируют значительно более качественные и

химически релевантные структуры, особенно в задачах, требующих точного контроля над стереохимией.

3.3 Перспективы развития: за пределами RNN и SMILES

Анализ ограничений классических подходов позволяет очертить три магистральных направления, по которым движется современная наука в области генеративного дизайна молекул: переход к более мощным архитектурам, переход к более естественным представлениям данных и, наконец, переход от 2D-структур к 3D-геометрии.

Тренд №1: От RNN к Трансформерам и большим языковым моделям. Рекуррентные нейронные сети, долгое время доминировавшие в задачах обработки последовательностей, постепенно уступают место архитектуре Трансформер. Благодаря механизму внимания (attention), трансформеры способны улавливать дальние зависимости в последовательностях, что делает их более мощным инструментом для моделирования сложных SMILES-строк. Эта тенденция нашла отражение в современных фреймворках, таких как **REINVENT 4**, где трансформерная модель была добавлена как опция для задач локальной оптимизации молекул [12]. Последующие работы показали, что обучение с подкреплением (RL) особенно эффективно именно в связке с трансформерами для целенаправленной генерации [20]. Апогеем этого тренда стало появление «фундаментальных моделей» (foundation models), таких как **GP-MOLFORMER**, обученных на миллиардах молекул. Эти модели, заимствуя парадигму из обработки естественного языка (NLP), демонстрируют беспрецедентную универсальность и производительность [21].

Тренд №2: От строк к графам. Как было показано ранее, строковые представления являются неестественными для молекул, которые по своей природе являются графами. Поэтому вторым ключевым трендом является все более широкое применение графовых нейронных сетей (GNN). Модель **JT-VAE** была одним из пионеров этого направления. Обширные обзорные работы подтверждают, что GCN (Graph Convolutional Networks) и другие варианты GNN сегодня являются передовой технологией для широкого спектра задач, от предсказания свойств до de novo генерации, так как они способны извлекать признаки напрямую из топологии молекулы, минуя «бутылочное горлышко»

строкового представления [22].

Тренд №3: От 2D к 3D. Наиболее передовым и сложным направлением является переход от генерации 2D-графов к генерации полноценных 3D-конформаций молекул. 3D-структура напрямую определяет биологическую активность, и ее моделирование является Святым Граалем вычислительной химии. На этом фронте доминирующим подходом стали **диффузионные модели**. Такие модели, как **GeoDiff**, обучаются обращать процесс постепенного зашумления 3D-координат атомов, генерируя физически правдоподобные и геометрически корректные структуры с соблюдением фундаментальных симметрий [23]. Как и в случае с 2D-моделями, эта бурно развивающаяся область уже столкнулась с необходимостью стандартизации, что привело к появлению комплексных бенчмарков для сравнения 3D-генераторов [24]. Финальным аккордом этого тренда можно считать появление моделей вроде **BindGPT**, которые объединяют в себе все три направления: используют архитектуру трансформера (LLM), работают с единым представлением, объединяющим 2D-граф (SMILES) и 3D-координаты, и интегрируют обучение с подкреплением для целенаправленной генерации молекул с высокой аффинностью к белковой мишени. Это демонстрирует путь к созданию единых, универсальных и мощных инструментов для полностью автоматизированного дизайна лекарств [25].

ЗАКЛЮЧЕНИЕ

В рамках курсового проекта было проведено всестороннее исследование методов представления и генерации молекулярных строк с использованием рекуррентных нейронных сетей и других архитектур глубокого обучения. Работа охватила анализ от базовых концепций, заложивших основу генеративной хемоинформатики, до передовых подходов, определяющих современное состояние области, и перспективных направлений ее будущего развития.

В ходе выполнения работы были получены следующие основные результаты в соответствии с поставленными задачами:

1. Проанализированы основы представления молекул для задач машинного обучения. Установлено, что нотация SMILES, благодаря своей текстовой природе, стала стандартом де-факто, позволившим применить мощные модели из области обработки естественного языка. Вместе с тем выявлены ее ключевые недостатки: проблема неканоничности, генерация синтаксически некорректных строк и семантическая неадекватность для представления сложных химических концепций.
2. Рассмотрены базовые генеративные модели. Показано, что рекуррентные нейронные сети (RNN) стали первыми архитектурами, доказавшими принципиальную возможность генерации новых, валидных и химически осмысленных молекул. В свою очередь, вариационные автоэнкодеры (VAE) ввели концепцию непрерывного латентного пространства, что открыло путь к контролируемой генерации и оптимизации свойств молекул путем навигации в этом пространстве.
3. Проведен детальный сравнительный анализ двух основных парадигм целевой генерации. Подходы на основе VAE и гетероэнкодеров реализуют не прямой контроль через структурирование латентного пространства, что обеспечивает высокое разнообразие генерируемых структур. Методы обучения с подкреплением (RL) осуществляют прямой контроль, напрямую максимизируя целевую функцию (вознаграждение), что обеспечивает исключительную гибкость, но сопряжено с риском «коллапса мод» и требует более сложных техник для поддержания разнообразия.
4. Исследованы проблемы оценки и ограничения существующих подходов.

Подчеркнута важность стандартизированных платформ, таких как MOSES, и комплексных метрик (например, FCD) для объективного сравнения моделей. Определены ключевые тенденции, которые будут формировать будущее генеративного дизайна молекул:

- **Переход к более мощным архитектурам:** от RNN к Трансформерам и большим языковым моделям (LLM).
- **Переход к более естественным представлениям:** от одномерных строк (SMILES) к графовым нейронным сетям (GNN), работающим напрямую с топологией молекулы.
- **Переход от 2D к 3D:** разработка моделей, способных генерировать не только граф связности, но и пространственную конформацию молекулы, что критически важно для предсказания биологической активности.

Таким образом, все поставленные задачи были выполнены, что позволило в полной мере достичь цели курсового проекта – провести комплексное исследование и анализ методов нейросетевой генерации молекул.

Результаты работы имеют практическую значимость, поскольку представленный анализ и систематизация подходов могут быть использованы специалистами в области хемоинформатики и дизайна лекарств для выбора наиболее подходящих инструментов и архитектур при решении задач *de novo* генерации молекул с заданными свойствами.

Дальнейшие исследования в этой области могут быть направлены на практическую реализацию и сравнение моделей, основанных на передовых подходах, таких как диффузионные модели для генерации 3D-структур или гибридные системы, объединяющие преимущества обучения с подкреплением и структурированных латентных пространств для достижения одновременно гибкой и разнообразной целевой генерации.

Библиографический список

1. De novo design of bioactive small molecules by artificial intelligence / D. Merk [et al.] // *Molecular informatics*. — 2018. — Vol. 37, no. 1/2. — P. 1700153.
2. Advances in de novo drug design: from conventional to machine learning methods / V. D. Mouchlis [et al.] // *International journal of molecular sciences*. — 2021. — Vol. 22, no. 4. — P. 1676.
3. In silico generation of novel, drug-like chemical matter using the LSTM neural network / P. Ertl [et al.] // *arXiv preprint arXiv:1712.07449*. — 2017.
4. *Wigh D. S., Goodman J. M., Lapkin A. A.* A review of molecular representation in the age of machine learning // *Wiley Interdisciplinary Reviews: Computational Molecular Science*. — 2022. — Vol. 12, no. 5. — e1603.
5. *Bjerrum E. J., Threlfall R.* Molecular generation with recurrent neural networks (RNNs) // *arXiv preprint arXiv:1705.04612*. — 2017.
6. *Bhadwal A. S., Kumari M., Kumar A.* PCF-VAE: posterior collapse free variational autoencoder for de novo drug design // *Scientific Reports*. — 2025. — Vol. 15, no. 1. — P. 34152.
7. *Richards R. J., Groener A. M.* Conditional β -VAE for de novo molecular generation // *arXiv preprint arXiv:2205.01592*. — 2022.
8. Generative model based on junction tree variational autoencoder for HOMO value prediction and molecular optimization / V. Kondratyev [et al.] // *Journal of Cheminformatics*. — 2023. — Vol. 15, no. 1. — P. 11.
9. *Bjerrum E. J., Sattarov B.* Improving chemical autoencoder latent space and molecular de novo generation diversity with heteroencoders // *Biomolecules*. — 2018. — Vol. 8, no. 4. — P. 131.
10. Генеративная нейронная сеть на основе модели гетероэнкодера для de novo дизайна потенциальных противоопухолевых препаратов: применение к Bcr-Abl тирозинкиназе / А. Карпенко [et al.] // *Информатика*. — 2023. — Vol. 20, no. 3. — P. 7–20.
11. String-based molecule generation via multi-decoder VAE / K. Kwon [et al.] // *ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. — IEEE. 2023. — P. 1–5.

12. Reinvent 4: modern AI-driven generative molecule design / H. H. Loeffler [et al.] // *Journal of Cheminformatics*. — 2024. — Vol. 16, no. 1. — P. 20.
13. Адаптация архитектуры нейронной сети REINVENT для генерации потенциальных ингибиторов проникновения ВИЧ-1 / Д. Воробьев [et al.] // *Информатика*. — 2024. — Vol. 21, no. 3. — P. 80–93.
14. Improving de novo molecular design with curriculum learning / J. Guo [et al.] // *Nature Machine Intelligence*. — 2022. — Vol. 4, no. 6. — P. 555–563.
15. *Guo J., Schwaller P.* Augmented memory: sample-efficient generative molecular design with reinforcement learning // *Jacs Au*. — 2024. — Vol. 4, no. 6. — P. 2160–2172.
16. Molecular sets (MOSES): a benchmarking platform for molecular generation models / D. Polykovskiy [et al.] // *Frontiers in pharmacology*. — 2020. — Vol. 11. — P. 565644.
17. Comprehensive survey of recent drug discovery using deep learning / J. Kim [et al.] // *International Journal of Molecular Sciences*. — 2021. — Vol. 22, no. 18. — P. 9983.
18. *Jin W., Barzilay R., Jaakkola T.* Junction tree variational autoencoder for molecular graph generation // *International conference on machine learning*. — PMLR. 2018. — P. 2323–2332.
19. fragSMILES as a chemical string notation for advanced fragment and chirality representation / F. Mastrolorito [et al.] // *Communications Chemistry*. — 2025. — Vol. 8, no. 1. — P. 26.
20. Evaluation of reinforcement learning in transformer-based molecular design / J. He [et al.] // *Journal of Cheminformatics*. — 2024. — Vol. 16, no. 1. — P. 95.
21. Gp-molformer: A foundation model for molecular generation / J. Ross [et al.] // *Digital Discovery*. — 2025. — Vol. 4, no. 10. — P. 2684–2696.
22. Graph convolutional networks for computational drug development and discovery / M. Sun [et al.] // *Briefings in bioinformatics*. — 2020. — Vol. 21, no. 3. — P. 919–935.
23. Geodiff: A geometric diffusion model for molecular conformation generation / M. Xu [et al.] // *arXiv preprint arXiv:2203.02923*. — 2022.

24. Comprehensive Benchmark Study of Diffusion-Based 3D Molecular Generation Models / Y. Qin [et al.] // ACS omega. — 2025. — Vol. 10, no. 37. — P. 42760–42775.
25. Bindgpt: A scalable framework for 3d molecular design via language modeling and reinforcement learning / A. Zholus [et al.] // Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 39. — 2025. — P. 26083–26091.