

ИССЛЕДОВАНИЕ МЕТОДОВ ПРЕДСТАВЛЕНИЯ И ГЕНЕРАЦИИ МОЛЕКУЛЯРНЫХ СТРОК С ИСПОЛЬЗОВАНИЕМ РЕКУРРЕНТНЫХ НЕЙРОННЫХ СЕТЕЙ

Кондратёнок Владимир Васильевич

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ

Кафедра биомедицинской информатики

Научный руководитель: старший преподаватель, А.Д. Карпенко

Минск, 2025

Цели и задачи

Цель работы

Комплексное исследование и сравнительный анализ современных методов представления и генерации молекулярных строк на основе нейронных сетей для задач целенаправленного дизайна молекул.

Задачи

- 1 Изучить теоретические основы представления молекулярных структур для задач машинного обучения, уделив особое внимание нотации SMILES.
- 2 Рассмотреть базовые архитектуры генеративных моделей (RNN, VAE) и их раннее применение.
- 3 Провести детальный анализ современных подходов к целевой генерации, включая оптимизацию в латентном пространстве и обучение с подкреплением (RL).
- 4 Исследовать проблемы стандартизации оценки моделей и определить перспективные направления развития.


Представление молекул: SMILES

SMILES (Simplified Molecular-Input Line-Entry System)

Формат, представляющий молекулу в виде строки символов ASCII. Позволил применить методы обработки естественного языка (NLP) к задачам медицинской химии.

Основные правила кодирования

- **Атомы:** Стандартные символы (C, N, O). Строчные буквы для ароматических систем.
- **Связи:** Одинарные по умолчанию, '=' для двойных, '#' для тройных.
- **Ветвления:** В круглых скобках '()'.
• **Циклы:** Разрыв связи в цикле, атомы помечаются одинаковыми цифрами.



Альтернативные представления молекул

Проблемы SMILES

- **Неканоничность:** Одна молекула может быть представлена множеством строк (например, CCO и OCC для этанола).
- **Синтаксические ошибки:** Модели часто генерируют невалидные строки (например, с непарными скобками).

Альтернативы

- **InChI (International Chemical Identifier):** Гарантирует абсолютно уникальную, каноническую строку для любой структуры.
- **Молекулярные графы:** Наиболее естественное представление (атомы – узлы, связи – ребра). Исключает синтаксически невалидные структуры.
- **SELFIES (Self-referencing embedded strings) и fragSMILES:** Гарантирует 100% синтаксическую валидность генерируемых строк.

Две основные философии:

① Оптимизация в латентном пространстве (VAE/Гетерозэнкодеры)

- Непрямой контроль.
- Задача: построить качественное, непрерывное представление химического пространства.
- Генерация и оптимизация являются вторичными задачами, выполняемыми внутри этого пространства.

② Прямая оптимизация политики (Обучение с подкреплением, RL)

- Прямой контроль.
- Задача: напрямую максимизировать заданную функцию вознаграждения (например, аффинность связывания).
- Модель обучается генерировать образцы, которые получают высокий балл.


Подход 1: Гетерозэнкодер

Проблема стандартного автоэнкодера

Разные SMILES-представления одной и той же молекулы отображаются в удаленные точки латентного пространства, делая его «зашумленным» и непригодным для навигации.

Решение: Гетерозэнкодер

Решает задачу «перевода» между различными, но семантически эквивалентными представлениями. Например, из канонической SMILES-строки в одну из множества случайных. Это заставляет модель изучать инвариантное, химически релевантное представление молекулы.




Подход 2: Reinforcement Learning (RL)

Основная идея

Прямое обучение генеративной модели (агента) максимизировать целевую функцию (вознаграждение) путем итеративного взаимодействия со «средой».

Ключевые компоненты (фреймворк REINVENT)

- **Состояние:** Текущая молекула.
- **Агент:** Генеративная модель (RNN), которая генерирует молекулы в виде SMILES-строк.
- **Действие:** Химический фрагмент для присоединения.
- **Среда:** Программный модуль, вычисляющий скалярную оценку (вознаграждение) для молекулы (QSAR, докинг).
- **Вознаграждение:** Целевая функция, которую агент стремится максимизировать.



Сравнительный анализ подходов

Критерий	Оптимизация в латентном пространстве	Прямая оптимизация
Разнообразие	Высокое. Модель аппроксимирует распределение данных.	Потенциально низкое. Склонность к эксплуатации найденных решений.
Требования к данным	Требуется крупный и разнообразный набор данных для обучения.	Используется предобученная модель. Не требуется специфический набор данных для оптимизации.
Гибкость	Низкая. Интеграция нового свойства требует переобучения.	Высокая. Новые свойства легко добавляются в функцию вознаграждения.
Интерпретируемость	Относительно высокая. Структура латентного пространства допускает визуализацию.	Низкая. Процесс принятия решений трудно интерпретируем.

Стандартизация оценки: бенчмарк MOSES

Проблема

Отсутствие единого стандарта для сравнения генеративных моделей. Исследователи использовали разные наборы данных и метрики, что делало невозможным объективное сравнение.

MOSES (Molecular Sets)

Бенчмарк, сосредоточенный на задаче обучения распределению.

- Предоставил большой, тщательно отфильтрованный набор данных.
- Ввел комплексный набор метрик для оценки (валидность, новизна, уникальность).
- Предложил специальный тестовый набор на основе **скаффолдов**, который позволяет оценивать способность моделей к генерализации и созданию молекул с новыми химическими каркасами.

Перспективы развития

Направление №1: От RNN к Трансформерам и большим языковым моделям

Архитектура Трансформер, благодаря механизму внимания, способна улавливать дальние зависимости в последовательностях, что делает ее более мощным инструментом для моделирования сложных SMILES-строк.

Направление №2: От строк к графам

Широкое применение графовых нейронных сетей (GNN), которые работают с более естественным представлением молекул, извлекая признаки напрямую из топологии.

Направление №3: От 2D к 3D

Переход от генерации 2D-графов к генерации полноценных 3D-конформаций с помощью диффузионных моделей. 3D-структура напрямую определяет биологическую активность.

Спасибо за внимание!